

Keelemudelite treenimine

Õppematerjal nullist: mis on tähtis, mis mida mõjutab,
ja mida tuleb teada, kui hakkad mudelit oma keele peale õpetama

Pert Lomp · september 2026

Kirjutatud ettevalmistuseks ettekandeks Eesti Keele Instituudis,
aga mõeldud kasutamiseks ka pärast seda, iga järgmise mudeli juures.

Kellele ja kuidas. See materjal eeldab, et sa ei ole kunagi mudelit treeninud. Iga mõiste seletatakse lahti seal, kus ta esimest korda ette tuleb, ja iga tehniline sõna saab eestikeelse vaste. Osad I–III annavad alused (mis on mudel, kuidas ta õpib, kuidas teda õpetatakse). Osad IV–VI on praktiline töö: seadistused, andmed, mõõtmine. Osad VII–VIII käsitlevad riistvara ja mudelimaastikku. Osa IX vastab küsimusele, mida ühe kaardi tööst saab üle kanda suurtele projektidele ja mida mitte. Osa X seob kõik meie oma projektiga, osa XI on vastused rasketele küsimustele, osa XII sõnastik.

Kuidas seda lugeda. Ära loe otsast lõpuni ühe hooga. Loe üks osa, pane käest, ja proovi endale valjusti seletada, mida sa lugesid. Kui seletus takerdub, mine tagasi. Kollasel taustal kastid on need kohad, mida tasub eriti meelde jätta, sest need on kas kõige sagedasem arusaamatus või kõige kallim viga.

Kuidas seda materjali kontrolliti ja miks siin nii palju parandusi on. Esimene mustand oli 30 lehekülge ja tundus valmis. Siis lasin selle üle vaadata kolmel sõltumatul mudelil korraga, korraldusega olla karm ja otsida just faktivigu ja liiga tugevaid üldistusi. Nad leidsid neid kokku üle neljakümne. Osa puudutas vananenud infot, osa minu enda ekslikke järeldusi, ja kolm viga puudutasid omavahel vastuolus olevaid arve. Nende järgi ajades leidsin oma projektist kolm vaikset viga, mida ma ei olnud märganud: viiendik treeningkorpusest ei jõudnud mudelini, korduse osakaal oli kolm korda väiksem kui ma arvasin, ja minu skoori nimetaja oli kaks ülesannet väiksem kui ma kirjutasin.

Ma jätsin need parandused teksti nähtavaks, koos sellega, mis mul algul valesti oli. Kaks põhjust. Esiteks: viga koos parandusega õpetab rohkem kui puhas lõpptulemus, sest see näitab, kus mõtlemine libiseb. Teiseks: kui ma lähen asjatundjate ette, on ainus mõistlik hoiak see, et ma tean oma töö nõrku kohti paremini kui nemad. Kui sa loed kohta, kus ma iseennast parandan, siis see ei ole vabandus. See on materjali kõige usaldusväärsem osa.

I osa. Mis on keelemudel ja kuidas ta õpib

1.1. Mudel on ennustusmasin

Keelemudel ei ole andmebaas ega otsingumootor. Ta on masin, mis teeb ainult üht asja: ennustab järgmist tükki teksti. Anna talle "Eesti pealinn on", ja ta arvutab, milline sõna kõige tõenäolisemalt järgneb. Ta arvutab tegelikult kõigi võimalike jätkude tõenäosused korraga, ja siis valib nende hulgast ühe.

Kogu ülejäänu (vestlemine, tõlkimine, kokkuvõtete tegemine, programmeerimine) on selle ühe oskuse tagajärg. Kui masin oskab piisavalt hästi ennustada, mis järgneb, siis oskab ta ka vastata küsimusele, sest küsimusele järgneb tekstis tavaliselt vastus.

Miks see sulle korda läheb. Kui mudel eksib eesti käändes, ei ole tal "vale teadmine" mingis lahtris, mida saaks parandada. Ta lihtsalt ennustas vale tähejada, sest see jada oli tema jaoks tõenäolisem. Treenimine tähendab nende tõenäosuste ümberseadmist, mitte fakti parandamist.

1.2. Token: mudel ei näe sõnu

Mudel ei tööta tähtede ega sõnadega, vaid tokenitega: tükkidega, milleks tekst on tükeldatud. Tükeldamise reeglistik on nimekiri, mis koostatakse mudeli ehitamisel. Suurusjärk on kümneid kuni sadu tuhandeid tükke; meie baasmudelil on neid 248 320.

Sagedased sõnad saavad terve tüki, harvad lagunevad. Need on tegelikud mõõtmised meie baasmudeli tükeldajaga, mitte näited:

```
"tere" → 1 [tere] "raamat" → 2 [ra][amat] "kirjutamata" → 4 [kir][jut][am][ata] "päevalillesse" → 4 [pä][eval][illes][se] "võimalikkusest" → 6 [v][ö][imal][ikk][use][st]
```

Pane tähele viimast rida: sõna alguses olev võ läheb kaheks eraldi tükiks, sest täpitäht on tükeldaja jaoks harv. Just seal, kus eesti keel on kõige eestikeelsem, on mudeli samm kõige lühem ja vigade risk suurim.

Miks see on eesti keele jaoks oluline. Tükeldajad on ehitatud peamiselt inglise keele peal. Meie mõõtsime oma korpusel (29 025 sõnast koosneval kõrvale pandud tekstikogumil): eesti sõna maksab 2,37 tokenit, inglise sõna 1,11. Vahe on 2,1-kordne. Kolm tagajärge:

1. Sama tekst maksab eesti keeles kaks korda rohkem. Kui mudeli kontekstiaknasse mahub 4000 tokenit, mahub sinna kaks korda vähem eesti teksti kui inglise oma. Sama kehtib API-arve kohta.
2. Haruldane käändevorm on mudelile pikem jada, mille iga lüli tuleb eraldi õigesti valida. See seletab kulu ja pikkust kindlalt. Ahvatlev on siduda sellega ka vigu nagu "päevalillesse", aga seda me ei tõestanud: sama viga võib tulla ka vormi harvusest korpuses või paradigma nõrgast õppimisest. Ütle ruumis kulu kohta kindlalt, vea põhjuse kohta ettevaatlikult.
3. Tükeldajat saab muuta, aga mitte järeltreeninguga üksi. Sõnastikku saab laiendada, ja siis tuleb muuta ka mudeli sisend- ja väljundkihti ning uued tükid välja õpetada (vt 1.8). Kogu mudelit nullist ehitama ei pea. Meie seda ei teinud: meie õpetasime mudelit olemasolevaid tükke hoolikamalt kokku panema.

1.3. Parameetrid: mis on "27 miljardit"

Kui öeldakse "27B mudel", tähendab see 27 miljardit parameetrit ehk arvu. Need arvud on mudeli mälu ja oskus korraga: kogu see, mida ta keelest ja maailmast teab, on nendesse arvudesse laiali

laotatud. Ühtegi konkreetset fakti ei ole ühes kindlas kohas.

Parameetreid nimetatakse ka kaaludeks. Treenimine tähendab nende arvude muutmist.

Mälukulu arvutamiseks: iga parameeter võtab tavaliselt 2 baiti. Ehk 27 miljardit parameetrit $\approx$ 54 gigabaiti. Sinu videokaardil on 32 GB, ehk mudel ei mahu, sellepärast on vaja tihendamist, millest tuleb juttu III osas.

Meie baasmudel täpselt. Kui sinult ruumis küsitakse, millega sa täpselt töötasid, ei piisa vastusest "27B mudel". Reprodutseeritav vastus on see (loetud mudelifailidest endist):

Mis	Väärtus
Arhitektuur	Qwen3_5ForConditionalGeneration, model_type qwen3_5
Parameetreid kokku	27,78 miljardit (loetud safetensors-failidest)
Tüüp	Multimodaalne (tekst + pildikäsitleja), tihe (mitte MoE)
Baas või vestlusmudel	Vestlusmudel: vestlusmall olemas, lõputoken < im_end >
Kihte	64
Peidetud mõõde	5120; vahekihi mõõde 17 408
Tähelepanu	24 päringupead, 4 võtmepead (GQA), pea mõõde 256
Sõnastik	248 320 tükki
Kontekst	kuni 262 144 tokenit

Üks detail, mille avastasid alles siis, kui adapteri faili lahti võtsin, ja mida ma ettekandes ise välja ütlen. Selles mudelis ei ole tavalist tähelepanu igas kihis: seda on ainult igas neljandas, ehk 16 kihis 64-st. Ülejäänud 48 kihti kasutavad teist tüüpi segamismehhanismi. Praktiline tagajärg minu tööle: minu adapter kattis kõigi 64 kihi edasisidekihid, aga jadade segamise ainult 16 kihis. See ei olnud teadlik valik, see tuli arhitektuurist. Kui keegi küsib, kas oleks saanud teisiti, on aus vastus: ma ei katsetanud seda ja ma ei tea.

1.4. Kuidas õppimine tegelikult käib

Kujuta ette 27 miljardit nuppu, igaüks keeratav. Õppimine käib nii:

1. Näita. Mudelile antakse tekstijupp ja kaetakse järgmine token kinni.
2. Lase ennustada. Mudel ütleb oma tõenäosused.
3. Mõõda viga. Kui õige vastus oli mudeli meelest ebatõenäoline, on viga suur. Seda viga nimetatakse kaoks (loss).
4. Arvuta süü. Masin arvutab tagurpidi läbi, kui palju iga nupp sellele veale kaasa aitas. Seda nimetatakse tagasileviks (backpropagation).
5. Keera nuppe. Iga nuppu keeratakse natuke õiges suunas. Kui palju keeratakse, määrab õpisamm (learning rate).
6. Korda miljoneid kordi.

See kirjeldus on lihtsustus, aga õiges kohas. Kui keegi küsib ruumis, kuidas õppimine käib, on see täiesti korrektne vastus.

Siin on koht, kus ma ise eksisin ja mille ma nüüd parandan, sest EKI ruumis on see otse pihta. Mu esimene mustand ütles, et mudel "ei jäta teksti meelde". See on vale. Õige on nii: mudel ei salvesta

teksti andmebaasikirjena, mida saaks üles otsida ja kustutada, aga ta võib osa treeningtekstist parameetritesse jäädvustada ja hiljem sõna-sõnalt välja anda. Seda on korduvalt mõõdetud nii avatud kui suletud mudelitel. See ei ole teoreetiline peensus, see on korraga isikuandmete risk ja autoriõiguse risk, ja just seda küsib arhiivi- või andmekaitseinimene esimesena.

Ausalt: ma ei teinud oma mudelile jäädvustamise testi. Nii et kui minult küsitakse, kas minu mudelist tuleb välja tükke koondkorpusest, on õige vastus "ma ei ole seda kontrollinud", mitte "ei tule". Kuidas seda kontrollida, on kirjas peatükis 5.8.

1.5. Kaks olekut: treenimine ja kasutamine

Treenimine on see, kui kaalusid muudetakse. See on aeglane ja nõuab palju mälu, sest lisaks mudelile tuleb hoida ka vahetulemusi ja optimeerija olekut.

Kasutamine ehk järeldamine (inference) on see, kui mudel ainult vastab. Kaalud ei muutu. Sinu Ollama jooksub mudelit selles olekus.

Tähtis järeldus: mudeli kaalud ei õpi vestlusest. Kui sa räägid mudeliga ja parandad teda, ei jää see kaaludesse. Järgmine kord alustab mudel samadest kaaludest.

Aga süsteemi käitumist saab püsivalt muuta ka ilma treeninguta, ja seda vahet tuleb hoida selgena, sest muidu tundub treening ainsa lahendusena, kui ta seda pole. Neli odavamate teed:

Lahendus	Mida ta teeb	Millal ta on parem kui treening
Süsteemiviip	Alaline juhised iga vestluse ees.	Tooni, rolli ja vormingu jaoks. Tasuta ja hetkega muudetav.
RAG (otsinguga toetatud vastamine)	Otsitakse dokumendist õige lõik ja pannakse see mudeli ette, enne kui ta vastab.	Faktide jaoks. Fakt muutub, sa muudad dokumenti, mitte mudelit. Ja saad allika välja näidata.
Väline mälu	Vestlustest korjatud fakti hoitakse failis ja söödetakse vajadusel ette.	Kasutajapõhine info, mida mudelisse ei tohigi panna.
Tööriistad	Mudel kutsub kalkulaatorit, otsingut, andmebaasi.	Kõik, mis peab olema täpne või värsk.

Reegel, mis säästab kõige rohkem raha: kui probleem on teadmine, alusta RAG-ist. Kui probleem on oskus, keel või käitumine, siis treeni. Mina treenisin, sest minu probleem oli keel: eestikeelsete sõnade käänamist ei saa dokumendist otsida.

1.6. Kontekstiaken

Mudel näeb korraga piiratud kogust teksti, seda nimetatakse kontekstiaknaks. Vanemad mudelid nägid 2000 tokenit, tänapäevased sadu tuhandeid (meie baasmudel kuni 262 000).

Treeningul valitakse aken teadlikult väiksemaks (meie kasutasime 2048 tokenit), sest mälukulu kasvab akna suurusega järsult. Väiksem aken tähendab, et saab treenida suuremat mudelit või kasutada suuremat partiit.

1.7. Temperatuur ja valimine

Kui mudel on arvutanud tõenäosused, tuleb neist üks valida. Temperatuur juhib, kui julgelt.

Temperatuur 0 tähendab praktikas, et võetakse alati kõige tõenäolisem variant. (Täpsuse huvides: nulliga jagamine ei ole matemaatiliselt defineeritud, nii et serverid tõlgendavad "temperatuur 0" kokkuleppeliselt kui ahnet valikut ehk greedy decoding. Kui keegi selle peale näpuga näitab, on tal õigus.) Vastused on siis korduvad ja igavad, aga ennustatavad. Temperatuur 0,7–1,0 annab mitmekesist ja loomingulisemat teksti, aga rohkem vigu. Meie kasutame vaikesi 0,4: piisavalt elav vestluseks, piisavalt täpne käänamiseks.

Ja üks hoiatus, mis puudutab otse mõõtmist. Temperatuur 0 ei anna veel korratavat tulemust. Sama viip võib anda eri vastuse ka nulli juures, kui GPU-tuumad, partii suurus või serveri versioon muutuvad. Kui sa avaldad numbri, pead kirja panema ka mudeliversiooni, serveri, partii ja seemne. Meie hindamisjooksudel oli seeme 20260822, temperatuur 0,3, top-p 0,9, top-k 40.

Kõrval on veel kaks nuppu, mida tasub teada, sest neid küsitakse: top-p (võta väikseim hulk tõenäolisimaid variante, mille kogutõenäosus on vähemalt 0,9) ja top-k (võta ainult k parimat). Kordustrahv (repeat penalty) vähendab juba öeldud sõnade tõenäosust, see on ravim selle vastu, kui mudel jääb lõputult sama fraasi kordama. Meil oli see päris probleem, kuni panime trahvi 1,15 peale.

1.8. Sõnastiku laiendamine: tee, mida ma ei käinud

Punktis 1.2 ütlesin, et tükeldajat saab muuta. Siin on, kuidas seda tehakse, sest see on täpselt see töö, mida EKI-suurune asutus saaks teha ja mina ühe kaardiga ei saanud. Kui keegi ruumis küsib "mis oleks õige lahendus", on see vastus.

Meetodi nimi on sõnastiku laiendamine (vocabulary extension). Loogika viie sammuna:

1. Uus eesti sõnastik. Võtad puhta eestikeelse korpuse ja treenid selle põhjal väikese tükeldaja (SentencePiece või BPE). See leiab need paar tuhat eesti tüve ja lõppu, mida baasmudelil ei ole.
2. Liitmine. Uued tükid lisatakse olemasoleva nimekirja lõppu. Meie mudeli puhul tähendaks see 248 320 olemasolevat ja näiteks 8000 uut tükki.
3. Tabeli suurendamine. Mudeli sisendkihti (embedding) ja väljundkihti (lm_head) lisatakse 8000 uut rida. See on koht, kus "tükeldaja muutmine" muutub mudeli muutmiseks.
4. Nutikas algväärtustamine. Uusi ridu ei jäeta juhuslikuks. Uue tüki "raamatusse" algväärtus arvutatakse nende vanade tükkide keskmisena, milleks mudel selle sõna varem lahti võttis. Nii ei alga mudel nullist, vaid sealt, kus ta juba oli.
5. Keele juurdevalamine. Alguses külmutatakse kogu mudel ja treenitakse ainult uusi ridu, siis avatakse ülejäänu ja tehakse jätku-eeltreening.

Mida see maksab ja mida ma EI luba. Ilmselge võit oleks lühem tokenijada ehk odavam ja kiirem eesti keel. Kui suur see võit on, ma ei tea, ja ma ei taha ruumis numbrit öelda, mida ma ei mõõtnud. Hind on seevastu kindel: uued read tuleb korralikult välja treenida, muidu läheb mudel esialgu halvemaks, ja tulemus ei ühildu enam vana tükeldajaga (adapterid, vahemälud, mõõtmised tuleb üle teha). Perpleksuse väärtusi ei saa enne ja pärast otse kõrvutada, sest tokenid on erinevad. See on suure projekti töö, mitte nädalavahetuse oma.

II osa. Mudeli elukaar: neli treeningufaasi

Mudel ei sünni valmis. Ta läbib faasid, ja iga faas teeb erinevat tööd. See on kõige olulisem mõisteline eristus kogu materjalis: kui sa selle selgeks saad, mõistad enamikku sellest, mida keegi mudelite treenimisest räägib.

2.1. Eeltreening (pretraining): mudeli sünd

Mis toimub. Mudel loeb hiiglaslikku kogust toorteksti (internet, raamatud, kood, kokku triljoneid tokeneid) ja õpib ainult üht asja: ennustama järgmist tükki. Ei mingeid küsimusi ega vastuseid, lihtsalt tekst.

Mida ta sealt saab. Keele enda: grammatika, sõnavara ja stiili ning kõrvalsaadusena tohutu hulk maailmateadmisi.

Kes seda teeb. Ainult suured laborid. Maksumus on kümneid kuni sadu miljoneid, tuhanded videokaardid kuudeks. Sina seda ei tee ega peagi tegema. Sina alustad kellegi teise eeltreenitud mudelist, seda nimetatakse baasmudeliks.

Üks arv, mida sageli valesti tsiteeritakse, ja ma tsiteerisin ka. Levinud on "20 tokenit iga parameetri kohta". See tuleb Chinchilla uuringust ja see ei tähenda seda, mida enamik arvab. See vastas kitsale küsimusele: kui mul on kindel arvutuseelarve, kuidas jagada see mudeli suuruse ja andmehulga vahel. See on treeningkulu optimum, mitte "nii palju keelt on vaja".

Tänapäeval treenitakse teadlikult palju üle selle suhte, sageli 200 kuni 500 tokenit parameetri kohta, sest kui mudelit hakkab kasutama miljon inimest, on kasutuskulu tähtsam kui treeningkulu. Väiksem, aga rohkem treenitud mudel on odavam jooksutada.

Mastaabi paika panemiseks võib seda ikkagi kasutada, kui ütled õigesti: kaasaegse retsepti järgi tahaks 27 miljardi parameetriga mudel vajaks eeltreeninguks suurusjärgus 5 kuni 14 triljonit tokenit. Minu 110 miljonit on sellest umbes kümnetuhandik. Ma ei teinud eeltreeningut. Ma tegin väikese keelekohanduse suure eeltreeningu otsa, ja see vahe on kogu asja juures kõige olulisem eristus.

2.2. Jätku-eeltreening (CPT): keele juurdevalamine

Mis toimub. Sama tegevus nagu eeltreeningul (toortekst, ennusta järgmist tokenit), aga juba valmis mudeli peal ja palju väiksemas mahus. Inglisekeelne nimi on continued pretraining või valdkonnakohane jätku-eeltreening (domain-adaptive pretraining).

Millal seda tehakse. Kui mudelil on keele või valdkonna auk: ta oskab vastata, aga tema keel on kohmakas, või ta ei tunne valdkonna sõnavara. Klassikalised kasutuskohad: väike keel (meie juhtum), meditsiin, õigus, ettevõtte sisemine žargoon.

Mida see annab ja mida EI anna. Annab loomulikkuse, sõnavara, rütmi. Ei anna oskust juhiseid järgida: CPT-järgne mudel võib olla suurepärane jutustaja, kes ei oska su küsimusele vastata, sest ta ei ole kunagi näinud, mis kuju vastus võtma peaks.

Meie mõõdetud tulemus: 110 miljonit tokenit toimetatud eesti proosat langetas mudeli üllatust kõrvale pandud eesti teksti ees 31 protsenti (perpleksus 22,2 → 15,4). Sama mudel läks kuivast valemist ("unistused täituvad, kui usud endasse") päris jutustamiseni (tüdruk, katkine teleskoop keldrikapis, tähistaevas).

Ja nüüd see, mille pärast ma selle numbri kaks korda üle lugesin. Ma kirjutasin algul kõikjale "131 miljonit tokenit". Ülevaatajad märkasid, et arv ei klapi ajaga: 131 miljonit tokenit 870 tokeni sekundikiirusega oleks 41,8 tundi, aga mõõdetud aeg oli 35,3. Läksin kontrollima ja leidsin kolm eraldi arvu, mida ma olin ühe pähe pidanud:

Arv	Väärtus	Mis see tegelikult on
Korpus sõnades	59,5 M sõna	1 248 706 väljavõetud tekstilõiku
Korpus tokenites (hinnang)	~131 M	Minu skript korrutas sõnad läbi oletatud suhtega 2,2 tok/sõna
Korpus tokenites (mõõdetud)	~141 M	Sama korpus päris tükeldajaga: suhe on 2,37, mitte 2,2
Mudelile jõudis	110,2 M	3364 sammu × 16 kuhjast × 2048 tokenit. See on ainus arv, mis kirjeldab tehtud tööd.

Miks vahe tekkis, ja see on materjali kõige kasulikum veakirjeldus. Ma pakkisin korpuse ~8000 tähemärgi kaupa tükkideks, arvestades 4 tähemärki tokeni kohta. Eesti keeles on see suhe tegelikult 2,75. Nii sai iga tükk umbes 2900 tokenit pikk, aga treeningaken oli 2048. Iga tükk lõigati otsast ära ja umbes viiendik korpusest ei jõudnud mudelini kunagi. Ükski logi ei öelnud selle kohta sõnagi, tekst lihtsalt kadus vaikselt.

Kontroll, mis oleks selle kohe leidnud, on üherealine: korruta sammud × kuhjamine × aken läbi ja vaata, kas tulemus klapi sellega, mida sa arvad end söötvat. Kui ma seda enne treeningut teinud oleks, oleks sama 35 tunniga läinud sisse kogu korpus. Ja tulemus oleks tõenäoliselt olnud parem, sest lõigatud sabad olid süstemaatiliselt lõikude lõpud, mitte juhuslik valim.

2.3. Juhendatud peenhäälestus (SFT): oskuste õpetamine

Mis toimub. Mudelile näidatakse paare: küsimus → õige vastus. Ta õpib mitte ainult sisu, vaid ka vastuse kuju: kui pikk, mis toonis, mis vormingus.

Inglisekeelne nimi supervised fine-tuning. Sõna "supervised" (juhendatud) tähendab lihtsalt seda, et õige vastus on ette antud.

Tähtis tehniline detail: treeningul arvestatakse viga tavaliselt ainult vastuse osast, mitte küsimusest. Mudel ei pea õppima küsimusi genereerima, ta peab õppima vastama. Seda nimetatakse ainult vastuse põhjal arvutatavaks kaoks (completion-only loss).

Näide meie andmetest:

kasutaja: Pane fraas 'habras tasakaal' mitmuse osastavasse käändesse. Vasta ainult vormiga, ilma selgitusega. assistent: hapraid tasakaale

Kõige olulisem õppetund selle faasi kohta (ja meie kalleim viga): mudel õpib TÄPSELT selle kuju, mida talle näidatakse. Me õpetasime 11 000 üksiksõna käänamist, aga test küsis fraase (omadussõna + nimisõna). Mudel ei olnud ühildumist kordagi näinud ja tulemus ei liikunud. 3000 õige kujuga näidet andsid kohe hüppe. Treeningnäite kuju peab vastama kasutuse kujule.

2.4. Eelistusõpe: kahe vastuse vahel valimine

Mis toimub. Mudelile näidatakse sama küsimust kahe vastusega: üks parem, teine halvem.

Siin oli mul teine eksitus, mille parandan. Ma kirjutasin, et eelistusõppes "ei õpi mudel sisu, vaid eelistust". Nii lihtne see ei ole: parem vastus ise on ka õppematerjal, nii et sisu kandub samamoodi üle. Õige eristus ei käi selle järgi, mida mudel õppida saab, vaid selle järgi, mida meetod optimeerib:

SFT tõstab õige vastuse tõenäosust. Tal ei ole aimugi, et mõni teine vastus oleks halvem, ta lihtsalt ei näinud seda.

DPO tõstab parema vastuse tõenäosust halvema suhtes. Signaal on suhtes, mitte üksikvastuses.

Praktiline tagajärg: DPO on tugev seal, kus viga on peen ja mõlemad vastused näevad välja usutavad. Täpselt selline on rööpvormi vale valik või natuke vale rektsioon. Sellist suhtelist eelistust SFT otseselt ei optimeeri: talle paistab ka halb vastus lihtsalt tekstina, mida ta pole näinud.

Miks seda üldse vaja on. SFT õpetab, mis on õige vastus. Aga sageli on mitu vastust "õiged" ja üks neist on parem: viisakam, ausam, täpsem, lühem. Seda vahet SFT ei õpeta.

Meetodite pere (neid küsitakse, sest nimesid on palju):

Nimi	Mis see on	Kas sina vajad
PPO-põhine RLHF	Klassikaline: eraldi hindajamudel õpetatakse inimeste eelistuste peal, siis treenitakse põhimudelit selle vastu stiimulõppega. Võimas, keeruline ja ebastabiilne. DPO ei ole seda asendanud: suured laborid kasutavad PPO-d ja uuemaid võrgus-õppe meetodeid edasi, sest hindajamudel oskab hinnata ka vastuseid, mida keegi pole ette valmis kirjutanud.	Ei, nõuab kolme mudelit korraga
DPO	Direct Preference Optimization. Sama eesmärk ilma õpitava hindajamudelita: võrreldakse otse paremat ja halvemat vastust. (Külmutatud viitemudelit ta siiski kasutab: seda, millest alustati. Vastasel juhul poleks millegi suhtes mõõta, kui kaugele mudel triivis.) Lihtne ja stabiilne. Meie kasutasime seda.	Jah, see on väikese tiimi vaikevalik
ORPO	Ühendab SFT ja eelistusõppe üheks sammuks. Sästab aega.	Võimalik, kui tahad ühe sammuga
KTO	Vajab ainult hinnangut "hea" või "halb", mitte paare. Kasulik, kui paare on raske koguda.	Kui sul on ainult üksikhinnangud

Kaks arvu, mida DPO juures teada. Beeta ütleb, kui kaugele mudel tohib algsest käitumisest triivida (väike beeta = suur vabadus = suur risk). Õpisamm peab olema kümneid kordi väiksem kui SFT-l.

Meie kaks katset, mis on hea õpetlik paar: esimene katse kasutas 9543 võõrast veapaari, beetat 0,1 ja liiga suurt õpisammu, kadu langes 0,0126 peale ja tulemus kukkus kuus punkti. Teine katse: 244 paari mudeli ENDA vigadest, beeta 0,3, õpisamm $3e-6$, üks epohh, pluss üks punkt. Sama meetod, vastupidised tulemused.

Ettevaatust selle 0,0126-ga. Mustandis kirjutasin, et see madal kadu tõestab päheõppimist. Ei tõesta. Madal kadu võib tähendada ka lihtsalt seda, et paarid olid liiga kerged: kui halb vastus on ilmselgelt halb, saab mudel need eristada ilma midagi kasulikku õppimata. See on märk, et vaadata edasi, mitte diagnoos. Diagnoosi annab ainult see, kui tulemus kõrvale pandud andmetel halveneb, mis siin õnneks ka juhtus, nii et järeldus oli õige, aga põhjendus oli vale.

2.5. Millises järjekorras

Eeltreening → CPT → SFT → eelistusõpe. See on hea tüüpiline retsept. Kirjutasin mustandis, et "iga järgmine faas eeldab eelmist", see on liiga tugev ja asjatundja parandab selle kohe ära.

Tegelikkuses: SFT-d saab teha ilma oma CPT-ta (enamik teebki nii), DPO-d saab tehniliselt teha ilma vahepealse SFT-ta, ja CPT-d saab teha ka vestluse mudelile, kui panna korpusesse vestlusnäiteid juurde või teha pärast taastav SFT.

Mis on tõsi, on põhjuslik mehhanism selle taga: toorteksti valamine vestlema õpetatud mudelile peseb vestlusoskuse maha, kui sa selle vastu midagi ette ei võta. Selle nimi on katastroofiline unustamine. Meie võtsime ette kaks asja: tegime CPT lähtemudelile, ja panime korpusesse veidi inglise keelt ja koodi tagasi (nn kordus, replay). Kui palju seda oli, on ausalt öeldes vähem kui ma arvasin: 3,1% sõnadest, mitte 10%, nagu ma esimeses mustandis kirjutasin.

Ja meie mõõdetud üllatus: ka faaside sees on järjekord tähtis. Sama SFT-andmehulk ühe suure annusena andis 76,5 protsenti, samad andmed 13 väikese ringina, kus iga ring nägi eelmise vigu, andsid 85,3. Iteratsioon ise on osa õppimisest, mitte lihtsalt andmete kohaletoimetamise viis.

III osa. Kuidas treenida, kui sul pole andmekeskust

3.1. Probleem

Kui tahaksid kõiki 27 miljardit parameetrit ümber treenida, peaksid mälus hoidma: mudeli kaalud (54 GB), gradiendid ehk parandussuunad (veel 54 GB) ja optimeerija olekud (tavaliselt kaks korda rohkem, ~108 GB). Kokku üle 200 gigabaiti. Sinu kaardil on 32.

Lahendus on parameetritõhus peenhäälestus (PEFT, parameter-efficient fine-tuning): ära puutu enamikku parameetrid, õpeta juurde väike lisaosa.

3.2. LoRA: kuidas see töötab

LoRA tähendab Low-Rank Adaptation, madala astaku kohandus. Idee on lihtne ja ilus.

Mudeli sees on suured arvutabelid (maatriksid). Täistreening muudaks kogu tabelit. LoRA jätab tabeli puutumata ja õpetab juurde kaks väikest tabelit, mille korrutis annab muudatuse. Kui algne tabel on 5120×5120 (üle 26 miljoni arvu), siis LoRA tabelid võivad olla 5120×16 ja 16×5120 , kokku 164 000 arvu, ehk 160 korda vähem.

$\text{kaal_uus} = \text{kaal_vana} + (B \times A) \times (\alpha / \text{rank})$ ↑ külmutatud ↑ ainus osa, mida õpetatakse

See juurdeõpetatud osa ongi adapter: eraldi fail, mis üksi ei tee midagi, aga baasmudeli peale pandult muudab tema käitumist. Meie adapterid on 640 MB, baasmudel 52 GB.

Kaks praktilist eelist, mida tasub ruumis mainida. Esiteks, adaptereid saab vahetada nagu objekte: sama baasmudel, mitu keelt või valdkonda. Teiseks, adapteri saab lõpuks kaaludesse sisse arvutada ("liita"), ja siis on tulemuseks üks tavaline mudel, mille kasutaja jaoks pole vahet, kuidas ta tehti.

3.3. Rank ja alpha: mida need päriselt teevad

Seda küsitakse peaaegu kindlasti, sest need on ainsad kaks arvu, mida LoRA juures ise valida tuleb.

Rank (r) on nende väikeste tabelite kitsam mõõde ehk adapteri mahutavus: kui suure astakuga muudatust adapter saab esitada. Tüüpilised väärtused on 8, 16, 32, 64, 128.

Alpha on mõjujõud: kui tugevalt õpitu baasmudelit mõjutab. Tegelik skaala on alpha jagatud rankiga. Levinud tava on hoida alpha kaks korda suurem kui rank ($r=16$, $\alpha=32$), mis annab skaala 2. See on tava, mitte reegel: nähtud on ka $\alpha = \text{rank}$ ja $\alpha = 4 \times \text{rank}$, ja rsLoRA kasutab hoopis teistsugust skaleerimist (jagab ruutjuurega, mitte rankiga, just selleks et suured rankid ei jääks alaskaleerituks).

Rank	Millal sobib	Risk
4-8	Väike stiilikohandus, vähe andmeid (alla paari tuhande näite).	Ei mahuta suuremat muutust
16	Tavaline valik oskuste õpetamiseks. Meie SFT-ringid. 79,7 miljonit treenitavat parameetrit (0,29% mudelist).	Enamasti õige valik

Rank	Millal sobib	Risk
32	Suurem muutus, uus keel või valdkond. Meie jätku-eeltreening. 159,4 miljonit parameetrit (0,574% mudelist, loetud adapterifailist).	Vajab rohkem andmeid, muidu õpib pähe
64-128	Väga suur nihe, palju andmeid (sajad tuhanded näited).	Kallis, ja hakkab kaotama LoRA eelist

Meie kogemus, mis on hea vastus küsimusele "kas suurem on parem": ei olnud. Rank 32 andis ühe ringiga parema tulemuse kui rank 16 (73,7 vs 67,3), aga jäi siis seisma, järgmised ringid ei liigutanud teda (73,7 → 73,3). Rank 16 tõusis edasi kuni 85,3-ni. Sellepärast valisin esimeses ahelas oskuste õpetamiseks rank 16.

Ja siis läheb lugu keerulisemaks, selle avastasin alles siis, kui seda materjali kontrollides adapterite failid ükshaaval lahti võtsin. Pärast jätku-eeltreeningut algas uus ahel rank 32 pealt, sest CPT-adapter oli rank 32. Ja minu lõplik tšempionmudel, see 86,1-punktiline, on rank 32, mitte 16. Seesama rank, mille kohta ma kirjutasin, et ta "jäi seisma", andis lõpuks parima tulemuse.

See ei kustuta esimest mõõtmist ära, aga see pöörab järelduse ümber. Õige järeldus ei ole "rank 16 on parem". Õige järeldus on, et üks jooksupaar ei kandnud seda üldistust, mille ma sellele peale panin. Ma jätan selle loo materjali just sellepärast, et ta näitab, kui kergesti sünnib ühest mõõtmisest "reegel", mida keegi hiljem tsiteerib, ja sellel juhul oleks tsiteerija saanud vale nõu minu enda tulemuse vastu.

Kuidas ma seda ruumis esitan, ja miks mitte teisiti. Kiusatus on öelda "rank 32 küllastus". Aga ma tegin ainult ühe jooksu kummagi väärtusega, ja need kaks jooksu ei olnud muidu identsed. Sama mustri võib täiesti sama hästi tekitada õpisamm, mis oli rank 32 jaoks vale, või lihtsalt see, et suurem adapter jõudis testi järgi valitud ülesannete tippu kiiremini. Aus sõnastus on: "minu kahe jooksu võrdluses käitusid need nii; põhjust ma ei isoleerinud". Katse, mis selle lahendaks, on lihtne ja tegemata: samad andmed, sama sammuarv, sama õpisammu otsing mõlemale, kolm seemet.

3.4. QLoRA: kuidas 52 GB mahub 32 GB kaardile

QLoRA on LoRA, mille juures baasmudelit hoitakse mälus tihendatud kujul: iga parameeter 16 biti asemel 4 bitiga. 54 GB muutub ~14 GB-ks ja mahub ära.

Kolm asja, mis QLoRA taga on ja mille nimesid tasub teada:

NF4 (NormalFloat 4): nutikas 4-bitine vorming, mis on häälestatud just selle jaotuse peale, mida närvivõrgu kaalud tegelikult järgivad.

Topeltkvantimine (double quantization): kvanditakse ka kvantimise abiandmed.

Lehitsetav optimeerija (paged optimizer): kui mälu saab otsa, kolitakse osa ajutiselt tavamällu, selle asemel et kokku kukkuda.

Tähtis: tihendatud on ainult baas, mida ei õpetata. Adapterit hoitakse suuremas täpsuses, tavaliselt 16 bitti (BF16), mitte 4. Ma kirjutasin mustandis "täistäpsuses", mis tähendaks 32 bitti, ja see ei ole õige: 32 bitti on tavaliselt ainult optimeerija sisemine olek. Nii et: baas 4 bitti, adapter 16, optimeerija arvepidamine 32.

Ja mida QLoRA kohta tohib lubada. Algne QLoRA töö näitas, et nende katsetes tuli tulemus 16-bitise LoRA-ga võrreldav. See ei ole garantii iga mudeli, iga keele ja iga faasi kohta, ja eriti mitte jätku-eeltreeningu kohta, mida seal ei mõõdetud. Aus lause on: "minu tingimustes ei olnud

tihendamine see, mis tulemust piiras" , ja isegi seda ma ei kontrollinud kõrvutikatsega, sest 16-bitine baas ei mahu 32 GB kaardile ära.

3.5. Muud meetodid, mida tasub nimepidi teada

Meetod	Idee	Millal
Täispeenhäälestus	Kõik kaalud muutuvad. Suurim kohandusvõime, tohutu hind. Tähelepanu: see ei tähenda automaatselt paremat tulemust. Väikese andmehulga juures võib LoRA olla parem, sest tema piiratud mahutavus vähendab päheõppimise ja unustamise riski.	Kui on andmekeskus JA palju andmeid
LoRA / QLoRA	Väike juurdeõpetatav kiht.	Vaikevalik ühe kaardiga
DoRA	LoRA edasiarendus: eraldab muudatuse suuruse ja suuna. Sageli veidi parem, veidi aeglasem.	Kui LoRA jääb kitsaks
rsLoRA	Parandatud skaleerimine, mis muudab suured rankid kasulikumaks.	Kui kasutad rank 64+
Prefiksi- ja viibahäälestus (prefix, prompt tuning)	Ei muuda kaale üldse, õpetab juurde nähtamatu eessõna. Väga odav, aga nõrgem.	Väga kitsas ülesanne
Mudelite liitmine (merging)	Kaks eri oskustega mudelit liidetakse kaalude tasandil kokku.	Oskuste ühendamise ilma treeninguta
Destilleerimine	Suur mudel õpetab väiksemat.	Kui vajad väiksemat mudelit

3.6. Mis on Mixture-of-Experts (MoE)

Seda kohtad mudelite nimedes ja tasub teada, mida see tähendab. Tavamudelil osalevad iga tokeni juures kõik parameetrid. MoE-mudelil on parameetrid jagatud "ekspertideks" ja iga tokeni juures aktiveeritakse ainult mõned. Nii saab mudel olla väga suur (näiteks 35 miljardit parameetrit), aga töötada nii kiiresti nagu palju väiksem (3 miljardit aktiivset).

Nimedes on see sageli kirjas kujul 35b-a3b: 35 miljardit kokku, 3 miljardit aktiivset. Treenimine on MoE peal keerulisem ja adapteritega vähem sissetallatud rada, meie valisime teadlikult tiheda (dense) mudeli.

3.7. Mudelite sulatamine: oskuste ühendamine ilma treeninguta

Kujuta ette kaht meistrit. Üks on läbi lugenud eesti ilukirjanduse ja räägib ilusat keelt. Teine on lahendanud tuhandeid programmeerimisülesandeid. Kuidas panna nad ühte pähe?

Ilmne tee on treenida kõike otsast peale. Aga on olemas ka teine tee, mille nimi on mudelite sulatamine (model merging): kahe mudeli kaalud liidetakse matemaatiliselt kokku. Ilma ühegi treeningtunnita ja ilma videokaardita, see on failitehe, mis käib tavalises arvutis minutitega.

Meetod	Kuidas töötab	Analoogia
SLERP	Liigub sujuvalt mööda kera pinda ühe mudeli kaaludest teise poole, mitte otse läbi keskkoha. Toimib kahe mudeli vahel.	Kahe värvi sujuv segamine
TIES	1) viskab välja tühised pisimuutused; 2) lahendab suunakonfliktid, kui üks mudel tahtis arvu tõsta ja teine langetada; 3) liidab ainult selle, milles mudelid on ühel meelel.	Koosolek, kus vaieldavad piasjad jäetakse kõrvale
DARE	Kustutab juhuslikult suure osa adapteri pisimuudatustest ja võimendab allesjäänuid vastavas suhtes.	Müra eemaldamine, et jääks ainult kontuur

Miks see EKI kontekstis oluline on. See tähendab, et eesti keele adapter ei pea olema seotud ühe konkreetse tootega. Kui keegi teeb hea eesti keele kohanduse ühele baasmudelile, saab selle põhimõtteliselt sulatada kokku hoopis teiste oskustega mudeliga. See on odavaim viis, kuidas väikese keele töö saab elada kauem kui üks mudelipõlvkond.

Aus piir: mina seda ei teinud. Ma ei ole sulatanud ega mõõtnud, kui palju sulatamisel kaotsi läheb. Tean, et see töötab paremini siis, kui mudelid tulevad samast baasist, ja et see ei ole tasuta, midagi läheb alati katki. Kui keegi ruumis on seda teinud, tahan tema numbreid kuulda rohkem kui oma arvamust öelda.

IV osa. Seadistused: mis mida mõjutab

Need on numbrid, mille sa treeningu käivitamisel ette annad. Neid nimetatakse hüperparameetriteks: "hüper" sellepärast, et need ei ole mudeli sees õpitavad, vaid sina otsustad need enne. Vale valik siin on kõige sagedasem põhjus, miks treening ebaõnnestub.

4.1. Õpisamm (learning rate): kõige tähtsam number

Mis see on. Kui suure sammu mudel iga paranduse juures teeb. Kirjutatakse tavaliselt teaduslikus vormis: $2e-5$ tähendab 0,00002.

Analoogia: kujuta ette, et laskud udus mäest alla ja otsid orgu. Õpisamm on su sammu pikkus. Liiga pikk samm hüppab orust üle ja sa põrkad seinast seina. Liiga lühike samm tähendab, et sa ei jõua kunagi kohale.

Väärtus	Millal kasutada	Mis juhtub, kui vale
$1e-4 - 5e-5$	Esimene ring puhta baasmudeli peal, palju uut materjali.	Liiga suur: mudel unustab vana, hakkab lolli juttu ajama
$2e-5$	Tavaline SFT-ring. Meie kasutasime seda ringides.	Turvaline vaikevalik
$1e-5 - 1,2e-5$	Hilisemad ringid, kui tahad ainult lihvida ja mitte olemasolevat lõhkuda.	Liiga väike: midagi ei muutu
$5e-6 - 8e-6$	Jätku-eeltreening (CPT). Meie kasutasime $8e-6$.	Suurem lõhub baasmudeli keeleoskuse
$1e-6 - 3e-6$	Eelistusõpe (DPO). Kümneid kordi väiksem kui SFT!	Suurem = kokkuvarisemine, mida me ise kogesime

Ja kohe hoiatus selle tabeli kohta. Need on minu logiraamatu arvud, mitte üldine õpetus. Õige õpisamm sõltub mudelist, adapterist, partii suuruselt, optimeerijast ja ajakavast. Kui keegi ruumis ütleb, et tema CPT käib $3e-5$ peal ja töötab hästi, siis tal on ilmselt õigus ja minu "8e-6-st suurem lõhub" kehtib minu seadistuse kohta. Võta tabelit lähtekohana, mitte reeglina.

Kuidas näha, et õpisamm on vale. Kui kadu (loss) hüpleb üles-alla või kasvab, on ta liiga suur. Kui kadu ei liigu üldse, on ta liiga väike.

Kolmas asi, mida ma valesti kirjutasin ja mis on tähtis parandada. Ma väitsin, et kadu alla 0,1 tähendab päheõppimist. See ei ole nii. Kadu on ülesandesõltuv arv: kui su ülesanne on lühike ja etteaimatav ("vasta ainult vormiga"), on 0,1 täiesti terve. Kui su ülesanne on vaba tekst, on 0,1 kahtlane. Sama number tähendab eri asju.

Päheõppimist ei näita kunagi treeningkadu üksi. Seda näitab ainult vahe: treeningkadu langeb edasi, aga kõrvale pandud andmetel mõõdetud kadu tõuseb. Ilma teise mõõduta ei ole sul diagnoosi, on ainult aimdus. Kuidas see praktikas käib, on peatükis 4.8, ja see on peatükk, mille ma pidin siia juurde kirjutama, sest esimeses mustandis seda ei olnud ja see oli materjali suurim auk.

4.2. Ajakava (scheduler) ja soojendus

Õpisammu ei hoita treeningu vältel ühesugusena. Ajakava muudab seda aja jooksul.

Soojendus (warmup): algul väga väike samm, mis kasvab paari protsendi jooksul täisväärtuseni. Koosinus-langus (cosine): pärast soojendust samm väheneb sujuvalt peaaegu nullini. Lõpupoole tehakse ainult peenhäälestust.

Lineaarne: sama, aga sirgjooneliselt. Vahe on väike.

Miks soojendust vaja on, õige põhjendusega. Mustandis kirjutasin, et "treeningu alguses on suunad juhuslikud". Ei ole. Suund arvutatakse esimesest sammust peale päris andmetest ja on täiesti sisukas. Õige põhjus on peenem ja seotud optimeerijaga: AdamW peab iga parameetri kohta meeles selle hiljutist liikumist ja kõikuvust (vt 4.6), ja treeningu alguses ei ole tal veel midagi meeles. Tema hinnang "kui kõikuv see parameeter on" põhineb ühel-kahel vaatlusel ja on seetõttu vale. Kui anda talle sel hetkel täissamm, teeb ta halva hinnangu põhjal suure sammu. Soojendus annab talle paarsada sammu aega, et arvepidamine kalibreeruks.

Meie jätku-eeltreeningul: soojendus 2 protsenti, siis koosinus. Ja siin ma tõmban tagasi ühe lause, mis oleks ruumis kohe vastu tulnud. Kirjutasin, et see on standardvalik, mida keegi küsimärgi alla ei sea. Ei vasta tõele: soojenduse pikkus ja ajakava valik on aktiivsed uurimisteemad. Kasutusel on 0%, 1%, 10%, fikseeritud sammuarvud, ja mitmesuguseid ajakavasid. 2% + koosinus on hea ja levinud lähtekoht, mitte lõpetatud küsimus.

4.3. Partii suurus ja gradiendi kogumine

Partii (batch) on see, mitu näidet vaadatakse enne, kui kaale muudetakse. Suurem partii tähendab stabiilsemat, vähem juhuslikku parandust, aga rohkem mälu.

Probleem: 27 miljardi parameetriga mudeli juures ei mahu ühe kaardi mällu kaks näidet korraga, rääkimata kaheksast.

Lahendus: gradiendi kogumine (gradient accumulation). Vaata üks näide, jätta parandus meelde, aga ära rakenda. Vaata järgmine, liida juurde. Ja alles pärast N näidet rakenda kogutud parandus korraga. Tulemus on matemaatiliselt peaaegu sama, mis suur partii, aga mälukulu on ühe näite oma.

meie seadistus: $\text{partii} = 1 \times \text{kogumine} = 16 = \text{efektiivne partii}$ 16

Miks see sind huvitab. Kui kellegi retseptis on "batch size 32" ja sul mälu ei jätku, ei pea sa loobuma: pane partii 1 ja kogumine 32. Aeglasem, aga sama tulemus.

4.4. Epohh ja samm

Epohh on üks täisläbimine kogu andmestikust. Samm on üks kaaluuuendus. Nende suhe:

$\text{sammude arv} = \text{näidete arv} \div \text{efektiivne partii} \times \text{epohhide arv}$

Mitu epohhi? Peenhäälestusel tavaliselt 1 kuni 3. Jätke-eeltreeningul enamasti 1, meil samuti.

Aga mitte "alati", nagu ma esimeses mustandis kirjutasin. Kaks parandust. Esiteks: eeltreeningul korraldatakse andmeid küll, eriti kui korpus on väike ja kvaliteetne, hiiglaslike veebikorpuste puhul püütakse kordust vältida, aga see on selle olukorra reegel, mitte üldine. Teiseks: "üle kolme epohhi tähendab peaaegu kindlasti päheõppimist" on samuti liiga tugev. Väikese, puhta andmestiku ja väikese õpisammuga võib viis epohhi olla täiesti õige. Epohhide arv ei ole otsus, mida numbri järgi teha, see on otsus, mida teha valideerimiskõvera järgi (4.8).

See valem päästis meil viis päeva. Meie jätku-eeltreeningu esialgne seadistus näitas 78 045 sammu, mis oleks võtnud kuus ja pool päeva. Aga 1,25 miljonit lõiku jagatud 16-ga ongi täpselt 78 045, mis

tähendas, et iga lõik läks eraldi näitena, ja "pakkimine" (millest räägin kohe) ei olnud sisse lülitunud, kuigi ma arvasin, et on. Pakkisin andmed ise kokku, sammude arv langes 3364 peale ja töö tehti 35 tunniga. Kontrolli alati, kas sammude arv vastab sellele, mida ootasid.

4.5. Pikkus ja pakkimine

Maksimaalne pikkus (max length) on see, kui pikka tekstijuppi treeningul korraga vaadatakse. Meil 2048 tokenit.

Probleem: kui su näited on lühikesed (näiteks 50 tokenit) ja aken on 2048, siis 97 protsenti arvutusest tehakse tühja täite peale.

Pakkimine (packing) tähendab lühikeste tekstide kokku kleepimist täis akendeks. Eeltreeningul on see hädavajalik.

Siin oli mul kõige vananenum väide. Kirjutasin, et juhendatud treeningul pakkimist tavaliselt ei tehta, sest näited segunevad. See oli kunagi tõsi ja ei ole enam: pakkimine on ka SFT-s täiesti tavaline. Segunemise probleem lahendatakse kolme asjaga:

1. Eraldajad. Iga näite lõppu pannakse lõputoken, nii et mudel näeb, kus üks asi lõpeb.
2. Kaomask (loss mask). Viga arvutatakse ainult vastuste pealt, mitte küsimuste ega täite pealt.
3. Plokkdiagonaalne tähelepanumask. See on see, mis probleemi päriselt lahendab: mudelil keelatakse ühest näitest teise vaadata, kuigi nad on samas aknas kõrvuti. Iga näide näeb ainult iseennast.

Ehk: probleem ei ole pakkimine, probleem on halvasti tehtud pakkimine. Kui su raamistik neid kolme asja teeb, on pakkimine puhas võit: meie SFT-näited olid 50–200 tokenit pikad ja aken 2048, ehk ilma pakkimata läks üle 90 protsendi arvutusest tühja.

Ja siin on minu enda kaks pakkimisvea lugu, mis on eri vead. Esimene: raamistiku pakkimine ei rakendunud ja ma ei märganud seda enne, kui sammude arvu üle lugesin (vt 4.4). Teine, mille avastasin alles seda materjali kontrollides: kui ma pakkimise ise ära tegin, arvestasin tükide pikkust tähelepanuta ja valesti: 8000 tähemärki ei ole eesti keeles 2000 tokenit, vaid ligi 2900. Iga tükk oli aknast pikem ja lõigati otsast ära. Umbes viiendik korpusest ei jõudnud mudelini ja ükski logi ei kurtnud.

Reegel, mille need kaks viga välja teenisid: pärast pakkimist mõõda tükide pikkus üle päris tükeldajaga, mitte tähe märkide arvu järgi. Üks käsk, kolm rida koodi, ja ta oleks mõlemad vead kohe leidnud.

4.6. Optimeerija

Optimeerija on see osa, mis otsustab, kuidas parandused päriselt kaaludesse kantakse. Tänapäevane standard on AdamW: ta peab iga parameetri kohta meeles kaht lisaarvu (kui kiiresti see parameeter hiljuti liikus ja kui kõikuv ta on olnud), et liikumine oleks sujuv.

Need lisaarvud on ka põhjus, miks treening võtab nii palju mälu. Sellepärast kasutatakse 8-bitist AdamW-d: sama asi, aga olek hoitakse tihendatult. Meie kasutasime `paged_adamw_8bit`, kus "paged" tähendab, et mälupuuduse korral kolitakse osa tavamällu.

4.7. Kokkuvõttev tabel: mis juhtub, kui vale

Seadistus	Liiga suur / palju	Liiga väike / vähe
Õpisamm	Mudel võib katki minna, unustada vana; kadu hakkab hüplema	Midagi ei muutu, aeg raisatud
Epohhid	Suurendab päheõppimise riski: testil hea, päris kasutuses halb	Ei jõua õppida
Rank	Kallis, suurendab päheõppimise riski, kaotab LoRA eelise	Ei mahuta muutust, jääb pinnapealseks
Partii (efektiivne)	Aeglane, ja väga suur ei anna enam kasu	Müra, ebastabiilne õppimine
DPO beeta	Mudel ei liigu kohalt	Triivib liiga kaugele, variseb kokku
Andmemahut	Aeg ja raha; üldine materjal võib isegi kahjustada	Ei üldista, õpib üksikjuhtumid

4.8. Valideerimiskadu: mõõteriist, mis mul puudus

See peatükk ei olnud esimeses mustandis ja see oli materjali suurim auk. Ma kirjutasin kogu aeg kaost, aga rääkisin ainult treeningkaost, arvust, mis mõõdab mudeli viga just nendel tekstidel, mida ta parajasti õpib. See arv üksi ei ütle sulle kunagi, kas õppimine on terve.

Analoogia, mis paneb kogu asja paika. Kujuta ette õpilast, kes valmistub eksamiks. Ta lahendab harjutusvihikut ja teeb aina vähem vigu. Kas ta saab ainest paremini aru, või on ta lihtsalt harjutusvihiku vastused pähe õppinud? Harjutusvihiku põhjal ei saa seda kunagi teada. Ainus viis on anda talle ülesanne, mida vihikus ei olnud.

Masinas käib see nii. Enne treeningut jagad andmed kaheks:

Treeningandmestik (90–95%): materjal, mida mudel näeb ja mille põhjal mudeli kaale muudetakse. Valideerimisandmestik (5–10%): tekstid, mis pannakse kõrvale. Nende põhjal ei muudeta mitte ühtegi parameetrit. Nende põhjal ainult hinnatakse mudelit.

Treeningu ajal arvutatakse siis kaht arvu. Treeningkadu mõõdab viga harjutusvihikus. Valideerimiskadu mõõdab iga paarisaja sammu tagant viga kõrvale pandud tekstidel. Ja siis tekib pilt, mille lugemine on kogu treenimise kõige olulisem üksikoskus:

```
kadu ^ | \ valideerimiskadu hakkab TÕUSMA -> päheõppimine | \ / | \_____/ <-- PARIM
HETK: siit tuleb mudel võtta | \ | \_____ treeningkadu langeb aina edasi
+-----> sammud
```

Terve õppimine: mõlemad langevad koos. Mudel saab asjast päriselt paremini aru.

Päheõppimine: treeningkadu langeb edasi, valideerimiskadu pöörduv ümber ja hakkab tõusma.

Käärde avanemine ongi diagnoos. Mitte ükski absoluutarv, vaid kahe kõvera lahknemine.

Kaks asja, mida see pilt lubab teha ja mis on kummalgi oma nimi. Kontrollpunktid (checkpointing): salvesta mudel kettale iga kord, kui valideerimiskadu saavutab uue madalaima taseme. Lõpuks ei võta sa viimast mudelit, vaid parimat. Varajane peatamine (early stopping): kui valideerimiskadu ei ole näiteks kolme kontrolli jooksul paranenud, lõpeta treening ise ära. Säästab aega ja elektrit ning hoiab ära mudeli rikkumise.

Ja nüüd aus osa. Ma seda ei teinud. Minu treeningutel oli ainult treeningkadu. Ma vaatasin selle asemel iga ringi järel oma 200-ülesandelist testi, mis on hoopis teine asi ja millel on oma tõsine hind, millest räägin peatükis 6.2. Praktiline tagajärg: ma ei tea, kas ükski minu adapter oli parimas punktis

või juba üle treenitud. Ma võtsin iga kord viimase sammu mudeli, sest mul ei olnud kõverat, mille järgi paremat valida.

Kui ma peaksin ühe asja tagantjärele teisiti tegema ja mul oleks aega täpselt ühe asja jaoks, siis see oleks see: võta enne esimest treeningut viis protsenti andmetest kõrvale ja mõõda kadu ka seal. See maksab paar protsenti arvutusajast ja annab sulle kõige otsesema üldotstarbelise mõõdiku selle kohta, millal peatuda.

V osa. Andmed: kus tegelikult otsustatakse

Valdkonnas on ütlus, et mudeli kvaliteet on andmete kvaliteet. Meie kogemus kinnitas seda mitu korda ja kõige valusamalt.

5.1. Kvaliteet lööb kvantiteeti

Meie kolm mõõdetud tulemust, mis on ka kolm head ettekandeslaidi:

Annus	Maht	Tulemus
Metateadmise faktid (käänete nimed, reeglid)	720 näidet	üks kategooria 0,8% → 57,7%
Verbireksioonid, kureeritud käsitsi	130 näidet	rektsioon 62,5% → 100%, üldskoor +2,1
Üldine materjal (saatevestlused, sõnaseletused)	81 268 näidet	üldskoor +1,1 (ja mõned kategooriad langesid)

Järeldus, mis on vastuoluline tavaarusaamaga: suur üldine andmehulk ei ole neutraalne täidis. Adapteril on piiratud mahutavus ja iga näide konkureerib ruumi pärast. Halvasti valitud materjal surub välja seda, mis oli juba õpitud.

5.2. Andmete kuju: vestlusmall

Iga vestlusmudel ootab teksti kindlas vormingus, kus on märgitud, kus algab kasutaja jutt ja kus vastus. Seda nimetatakse vestlusmalliks (chat template). Näiteks:

```
<|im_start|>user Pane fraas ... käändesse.<|im_end|> <|im_start|>assistant hapraid tasakaale<|im_end|>
```

Miks see on praktiliselt tähtis. Kui treenid ühe malliga ja kasutad teisega, käitub mudel katkiselt. Meil juhtus täpselt see: pakendasime mudeli Ollamasse ilma malli kirjelduseta ja mudel hakkas küsimusi tagasi kajama ja vastama eelmisele küsimusele. Mudel oli terve, pakend oli katki.

5.3. Puhastamine ja saaste

Enne treeningut tuleb andmed puhastada. Nimekiri, mis tasub läbi käia:

Dublikaadid: sama teksti korduv esitamine suurendab päheõppimise riski. Meie kasutasime räsi (iga lõigu algusest) ja viskasime kordused välja.

Masinajäägid: meil oli andmestikus 17 kirjet tekstiga "<nooutput>", mis on kellegi teise genereerimisvea jälg. Üks neist jõudis treeningusse ja mudel hakkas seda vahel väljastama.

Vale keel: kontrolli, et eesti korpus ei oleks juhuslikku inglise või vene teksti.

Tekstituvastuse vead: vanemad skaneeritud tekstid on täis vigaseid tähti.

Liiga lühike või liiga pikk: meie võtsime ainult lõigud, kus oli vähemalt 25 sõna.

5.4. Leke: kõige ohtlikum viga

Leke (contamination) tähendab, et testi ülesanded on sattunud treeningandmetesse. Siis mudel ei oska, vaid mäletab, ja sinu number on vale. See on kõige tavalisem põhjus, miks avaldatud

tulemused ei kordu.

Mida meie tegime: testi ülesanded ja nende sisusõnad (kokku 1467 sõna) filtreeriti igast treeninguannusest välja. Igal korpuse kirjel on väli eval_bloki, mis ütleb, kas seda kirjet tohib treeningus kasutada.

Aus enesekriitika, mida tasub ise välja öelda: ülesande tasandil leket meil ei ole, aga kategooria tasandil me sihtsime teadlikult just neid oskusi, mida test mõõdab. See on omamoodi testiks õppimine. Sellepärast ehitasime eraldi kontrolli: 378 käänamislahtrit, mida treening pole kunagi näinud. Seal on tulemus umbes kümme punkti madalam ja see arv on üldistuse kohta ausam.

5.5. Unustamine ja replay

Kui õpetad mudelile ainult üht asja, kaotab ta teisi. Seda nimetatakse katastroofiliseks unustamiseks.

Vastumeede on lihtne: sega treeningusse tükk vana tüüpi materjali. Selle nimi on kordus (replay). Soovitatav suurusjärk on kirjanduses tavaliselt 10–20 protsenti.

Mida meie päriselt tegime, kui ma logid üle lugesin:

Faas	Kordust	Kuidas mõõdetud
Jätke-eeltreening (CPT)	3,1% sõnadest	Korpuse ehitamise logist. Mustandis kirjutasin ~10%, see oli vale.
SFT-ringid	15–18% näidetest	Annuse koostise järgi. Näidetes, mitte tokenites.

Ja mida ma nende numbrite põhjal tohin väita. Mõõdetud on see: üldteadmiste test (MMLU eesti keeles) läks 68,7 pealt 66,0 peale, programmeerimine (HumanEval) 71,3 pealt 85,4 peale.

Kiusatus on öelda "kordus hoidis üldteadmised alles ja tõstis koodi". Seda ma öelda ei tohi, ja põhjus on lihtne: ma ei teinud sama treeningut ilma korduseta. Ilma kõrvutuseta ei ole mul põhjuslikku väidet, on ainult üks jooks. Pealegi räägivad numbrid ise osalt vastu: üldteadmised langesid 2,7 punkti, ja koodi tõusu mõõtsin ma mudeliversioonil, mis oli vahepeal mitu ringi edasi liikunud, nii et põhjuseid on mitu.

Aus sõnastus ruumis: "kasutasin kordust, sest kirjandus soovitab; katastroofilist unustamist ma ei näinud; kas kordus oli selle põhjus, ma ei mõõtnud." See on nõrgem lause kui "kordus töötas", aga see on lause, mida keegi ei saa ümber lükata.

5.6. Litsentsid

See on osa, mida tehnilised inimesed tavaliselt ignoreerivad ja mis akadeemilises ruumis loeb kõige rohkem.

Litsents	Mida lubab	Mida nõuab
CC0 / avalik omand	Kõike	Mitte midagi
CC-BY	Kõike, ka äriselt	Viita autorile

Litsents	Mida lubab	Mida nõuab
CC-BY-SA	Kõike	Viita JA jaga tuletisi sama litsentsiga. Tartu Ülikooli koondkorpus on selline (Kadri Muischnek, TÜ arvutilingvistika, kirjalikult 26.08.2026).
CC-BY-NC	Ainult mitteäriline	Viita
Määramata	Mitte midagi kindlat	Küsi enne kasutamist

Üks nüanss, mille pean ise välja ütleva, sest ruumis on inimesi, kes seda paremini teavad kui mina. Tabeli viimane veerg kirjeldab litsentsi ennast õigesti. Aga sellest ei järeldu automaatselt, et CC-BY-SA korpuse peal treenitud mudeli kaalud oleksid samuti CC-BY-SA all. Kas treenitud kaalud on juriidiliselt "tuletatud teos", on jurisdiktsiooniti lahtine ja vaieldav küsimus. Creative Commons ise nimetab AI-treeningu õiguslikku seisukohta keeruliseks ja eristab konservatiivset praktikat juriidilisest kohustusest.

Minu positsioon, mille ma ütlen välja täpselt nii: ma ei ole jurist, ma ei ole selle kohta õigusnõu küsinud, ja ma olen valinud konservatiivse tee: märgin allikad, avaldan sama litsentsi all, ja kui õiguste omanik ütleb, et ei sobi, võtan maha. See ei ole juriidiline argument, see on hoiak. Kui EKI-I on selle kohta seisukoht, tahan seda kuulda, sest see puudutab kõiki, kes eesti keele mudeleid avaldavad, mitte ainult mind.

Meie praktika: iga korpuse kirje kannab allika- ja litsentsivälja. Kirjed, mille litsents on määramata (2425 tükki), jäid avaldatavast paketist välja, kuni õigused selguvad.

Ja kohe ka teine pool, sest seda on kerge maha vaadata: avaldamisest väljas ei ole sama mis treeningust väljas. Osa märgistatud kirjetest oli treeningus sees. See oli teadlik otsus, mitte kogemata. Ma treenisin ilma kindla litsentsikinnituse ja hoidsin piiri avaldamise juures, mitte treeningu juures.

Miks ma nii otsustasin, ja miks ma ei esita seda reeglina. Kolm kaalutlust. Esiteks: treening on siin uurimistöö, mille tulemus on mõõtmine, mitte toode, ja mudel ise ei ole avaldatud nendest kirjetest koosnevana. Teiseks: kui ma oleksin oodanud iga litsentsi kinnitust, poleks tööd üheksa päevaga olemas ja poleks ka seda materjali. Kolmandaks: piir, mille ma tõmbasin, on avaldamine, sest just seal tekib levitamine ja just seal on kahju pöördumatu.

Aga ma ei väida, et see on õige vastus. See on koht, kus tehnilise inimese otsus asendab õigusnõu, ja ma tean seda. Euroopa tekstikaeve erandid, andmebaasiõigus ja see, kas mudelikaal on tuletatud teos, on kõik lahtised küsimused, mille kohta mul ei ole seisukohta, vaid ainult praktika. Ma ütlen selle ruumis ise välja, sest kui keegi selle hiljem üles leiab, on vestlus hoopis teine. Ja kui EKI-I on siin väljakujunenud praktika, tahan seda kuulda rohkem kui oma valikut kaitsta.

Miks see just praegu on tundlik. Eesti mäluasutuste avalikud kogud kukuvad praegu kraapimise koorma all: TalTechi digikogu ei tööta, Tartu metashare ei tööta. Kui sina ütled ruumis, et küsisid iga asja kohta kirja teel ja ei kraapinud midagi, siis see on täpselt see, mille pärast nad muretsesid.

5.7. Kui palju andmeid on vaja

Eesmärk	Kogus	Meie kogemus
Vastuse kuju ja tooni muutmine	500 – 2 000 näidet	130 näidet muutis ühe kategooria täielikult

Eesmärk	Kogus	Meie kogemus
Uus konkreetne oskus	2 000 – 10 000 näidet	3 000 fraasinäidet andsid +8 punkti
Lai oskuste komplekt	10 000 – 100 000	Meie ringid kokku ~50 000
Keele loomulikkus (CPT)	50M – 1 mld tokenit	110M andis –31% perpleksust kõrvale pandud tekstil
Uus keel nullist	10 – 100 mld tokenit	Meie mastaabist väljas

5.8. Andmeaudit: kordused, leke, isikuandmed, jäädvustamine

Andmehulga suurus ei ütle, kui palju sõltumatut infot seal on. Miljon lõiku võib sisuliselt olla sada tuhat lõiku, mida on kümnel veebilehel korratud. Ja treening- ning testikomplekt võivad jagada samu teoseid ilma ühegi identse lauseta.

Korduste eemaldamisel on kolm astet, mitte üks

Aste	Mida ta leiab	Mida ta EI leia
Täpne (räsi)	Identsed koopiad. Tekst normaliseeritakse (tühikud, jutumärgid, Unicode) ja võrreldakse sõrmejälgi.	Ühtegi muudetud koopiat
Ligikaudne	Väga sarnased tekstid. Tekst jagatakse lühikesteks sõnadadeks ja mõõdetakse kattuvust. Leiab sama artikli, millele on kuupäev ette lisatud.	Ümbersõnastust
Dokumendi tasand	Päritolu. Sama romaani eri peatükid ei ole identsed, aga kui pool romaanist on treeningus ja teine pool testis, mõõdab test osaliselt sama teose tuttavust.	Midagi, kui allikat ei ole kirjas

Mina tegin ainult esimese astme, ja sedagi kitsalt: räsi iga lõigu algusest. See ei leia ümbersõnastust, muudetud koopiat ega sama teose kattuvaid lõike. Nii et kui minult küsitakse, kas mu perplexity korpus oli treeningust päriselt eraldatud, on aus vastus: lõigu tasandil jah, teose ja autori tasandil ma ei kontrollinud. Ja kuna korpus on ilukirjandus, on täiesti võimalik, et sama autori teine peatükk oli treeningus. See ei kustuta tulemust samal tekstijaotusel, aga see muudab uutele autoritele üldistamise liiga optimistlikuks.

Isikuandmed

Avalikus tekstis on nimesid, aadresse, telefoninumbreid, kohtuasjade detaile ja haruldasi sündmusi, mille järgi inimene on tuvastatav. See, et tekst on avalik, ei tee neid andmeid riskivabaks. Audit peaks küsima viit asja: kas tundlikku teavet on; kas see on treeningu eesmärgi jaoks üldse vajalik; kas see tuleks eemaldada või varjata; kas allikas lubab sellist töötlust; ja kas mudel võib haruldase lõigu välja anda.

Jäädvustamise test: kolm viisi, kõik tegemata

Punktis 1.4 ütlesin, et mudel võib treeningteksti sõna-sõnalt meelde jätta. Siin on, kuidas seda kontrollida, ja ma kirjutan selle välja täpselt sellepärast, et ma ei ole seda teinud ja see on minu nimekirjas järgmine.

1. Jätkamiskatse. Võta haruldased treeninglõigud, anna mudelile nende algus, ja mõõda, kui pikalt ta jätkab sõna-sõnalt. See on kõige otsesem test ja kõige lihtsam teha.
2. Tõenäosuste võrdlus. Võta sarnased tekstid, millest osa oli treeningus ja osa mitte, ja võrdle, kui tõenäoliselt mudel neid peab. Kui ta eelistab treeningtekste ebaharilikult tugevalt, on see märk riskist, et keegi saab tuvastada, mis su andmestikus oli.
3. Kattuvuse otsing. Genereeri palju teksti ja otsi sealt pikki jadasid, mis kattuvad treeningkorpusega.

Ükski neist ei tõesta iseenesest õigusrikkumist. Nad näitavad, millised lõigud vajavad lähemat vaatamist. Riskipõhine järjekord: korduvalt esinevad lõigud, väga haruldased jadad, isikuandmeid sisaldavad tekstid, ja autoriõigusega kaitstud teoste pikad katkendid.

5.9. Mitmekäiguline vestlus: minu mudeli nõrgim koht

Kui treenid mudelit ainult üksikute küsimuste ja vastuste peal ("kääna sõna X" → "vastus Y"), saad väga hea ühe lause lahendaja ja väga kehva vestluspartneri. Minu mudel on täpselt selline: pikemas vestluses kaotab ta teema ja hakkab vahel kasutaja küsimust tagasi kajama. See ei ole müsteerium: minu peenhäälestusandmetes ei olnud ühtegi mitmekäigulist vestlust.

Treeningandmed peavad siis olema mitte üksikud paarid, vaid terved vestluste ajalood. Standardkuju on selline:

```
[{"role": "system", "content": "Sa oled eesti keele toimetaja."}, {"role": "user", "content": "Kas lause X on õige?"}, {"role": "assistant", "content": "Jah, aga loomulikult oleks Y."}, {"role": "user", "content": "Aga kui asendada Z-ga?"}, {"role": "assistant", "content": "Kehtib sama reegel: ..."}]
```

Ja siin on üks tehniline detail, mis otsustab, kas see töötab. Viga arvutatakse ainult assistendi vastuste pealt. Süsteemiviip ja kasutaja repliigid maskitakse kinni. Põhjus on lihtne: me ei taha, et mudel õpiks ennustama, mida inimene järgmiseks küsib. Me tahame, et ta õpiks vastama, arvestades seda, mis enne oli. Kui maskimine (masking) on vale, õpib mudel vestlust kirjutama, mitte selles osalema, ja just see näeb välja nagu kajamine.

Süsteemiviiba järgimine on eraldi oskus, mida tuleb eraldi õpetada. Süsteemiviip on mudeli tööjuhend vestluse alguses. Et ta sellest päriselt kinni peaks, peavad treeningandmetes olema teadlikult erinevad juhendid koos neile vastavate vastustega: üks näide ütleb "vasta väga lühidalt", teine "vasta ametlikus registris", kolmas "keeldu, kui palutakse midagi ohtlikku". Alles siis õpib mudel üldise reegli, et süsteemiviip määrab tema tooni, piirangud ja pikkuse. Kui kõik näited on sama juhendiga, õpib ta selle juhendi sisse ja ignoreerib kõiki teisi.

Miks ma seda ei teinud, ja mis on selle peatüki mõte. Päris eestikeelset mitmekäigulist dialoogi ei ole avalikult peaaegu üldse. Tõlgitud dialoog toob sisse tõlkelisuse, mida ma just parandama tulin. Vikipeedia arutelulehed on selles mõttes haruldane materjal: päris inimeste päris eestikeelne vestlus, kus üks vastab teisele ja teema areneb. Kui ma pean nimetama ühe andmestiku, mis minu mudeli nõrgima koha ära parandaks, siis see on see.

5.10. Sünteetilised andmed ja tagasilükkega valik

Käsitsi 50 000 kvaliteetse treeningnäite kirjutamine võtaks aastaid. Sellepärast toodetakse tänapäeval enamik peenhäälestusandmeid masinaga: üks mudel genereerib teisele õppematerjali. Ja siis tekib ilmne oht: masin toodab ka vigu, ja kui need valatakse otse treeningusse, õpib uus mudel vead ära.

Tagasilükkega valik (rejection sampling) on lahendus, mis on korraga lihtne ja väga tõhus. Selle asemel, et võtta üks genereeritud vastus, lased genereerida mitu ja hoiad alles ainult need, mis läbivad range kontrolli:

küsimus → genereeri 5 vastust → kontrolli kõik → hoia alles ainult veatu vastus 1 vigane → prügi vastus 2 ebatäpne → prügi vastus 3 VEATU → treeningusse vastus 4 vigane → prügi vastus 5 vigane → prügi

See on täpselt see, mida ma tegin, ainult ma ei teadnud, et sellel on nimi. Minu kontrollijaks ei olnud teine keelemudel, vaid Vabamorf. Sellel on üks selge eelis: morfoanalüsaator on reeglipärane ja korratav, ta ei hallutsineeri ega meelita, ta lihtsalt ütleb, kas vorm on tema andmetes olemas. Aga ta ei ole eksimatu oraakel, ja miks mitte, on kirjas peatükis 6.9.

Kui kontrollijaks on teine mudel (nn mudel kohtunikuna, LLM-as-a-judge), on kaks kallutatust, mida peab teadma, sest mõlemad on hästi dokumenteeritud:

Pikkuse eelistus. Mudelid peavad pikemat vastust peaaegu automaatselt paremaks kui lühikest ja tabavat. Hindamisjuhendis tuleb lühidust eraldi premeerida, muidu ajad mudeli lobisema.

Järjekorra eelistus. Kui anda kaks vastust võrdluseks, eelistab kohtunik sageli esimest lihtsalt sellepärast, et ta on esimene. Ravi: vaheta järjekord läbi ja vaata, kas hinnang jääb samaks. Kui ei jää, ei ole see hinnang.

VI osa. Mõõtmine: ilma selleta ei tea sa midagi

Kui pead kogu materjalist meelde jätma ühe asja, siis selle: ehita mõõt enne, kui hakkad treenima. Ilma selleta ei ole sul võimalust teada, kas su töö aitas või kahjustas, ja sa hakkad otsuseid tegema tunde järgi.

6.1. Miks oma test

Avalikke teste on olemas, aga need mõõdavad üldist võimekust. Kui su probleem on eesti käänamine, ei ütle ükski neist sulle, kas käänamine läks paremaks. Sellepärast tegime oma testi: 200 ülesannet, ehitatud just nende vigade peale, mida baasmudel tegi.

Lukustamine. Test tuleb fikseerida ja mitte muuta, muidu ei ole eri ajahetkede numbrid võrreldavad. Meie kasutame räsi (SHA-256), mis on faili sisust arvutatud sõrmejälj, kui keegi faili muudab, muutub räsi ja ma näen seda kohe.

6.2. Kolm andmehulka, mitte kaks, ja minu kõige tõsisem viga

See peatükk on materjali kõige tähtsam osa. Kui sa loed ainult ühte peatükki, loe seda. Ja kui keegi EKI-s tahab minu tööd põhjalikult kritiseerida, on siin täpselt see koht, kust ta alustab, nii et ma alustan sealt ise.

Kolm rolli, mida tavaliselt aetakse segi

Nimi	Mida temaga tehakse	Kui tihti tohib vaadata
Treeningandmestik (train)	Mudel näeb seda ja tema kaale muudetakse selle põhjal.	Pidevalt. See ongi õppematerjal.
Valideerimiskomplekt (validation, dev)	Mudel EI näe seda treeningul, aga sina vaatad seda ja teed selle põhjal otsuseid: mis õpisamm, mitu epohhi, milline kontrollpunkt, mis järgmiseks treenida.	Nii tihti kui vaja; selle komplekti ülesanne ongi arendusotsuseid toetada.
Testikomplekt (test, holdout)	Mitte keegi ei vaata seda enne, kui kõik otsused on tehtud. Vaadatakse üks kord, päris lõpus, ja siis öeldakse tulemus välja.	Üks kord. Iga järgmine kord nõrgendab teda.

Miks testi korduv vaatamine ta ära rikub

See ei ole vormitäide ega akadeemiline peenutsemine. Mehhanism on konkreetne ja seda on lihtne näha.

Analoogia. Kujuta ette, et koostad kellelegi eksami ja annad hinde. Aga enne päris eksamit lased tal seda sama eksamit teha kolmteist korda ja pärast igat korda ütled: "kolmandas küsimuses sa eksisid, harjuta seda tüüpi ülesandeid". Kolmeteistkümnenda korra hinne on suurepärane. Aga see ei ütle sulle enam, kas ta oskab ainet. See ütleb, kui hästi ta oskab seda eksamit. Info eksami sisust on kolmteist korda tema õppimisse sisse jooksnud, mitte ühegi küsimuse kaudu, vaid sinu otsuste kaudu selle kohta, mida talle õpetada.

Täpselt seda ma tegin. Minu töövoog oli iga ringi juures sama: jooksuta test → vaata, milline kategooria on kõige nõrgem → tee sinna kategooriasse uus treeningannus → treeni → jooksuta test uuesti. Kolmteist korda. Ükski testi ülesanne ei sattunud treeningandmetesse (seda ma kontrollisin, vt 5.4), aga see ei ole see, mis siin katki läks. Katki läks see, et test juhtis treeningu sisu.

Sellel on ka nimi. Kui testi kasutatakse otsuste tegemiseks, on ta definitsiooni järgi valideerimiskomplekt, mitte test. Ja ma ei nimetanud teda kunagi ümber. Minu 200-ülesandeline "lukustatud test" oli kolmeteistkümnenda ringi lõpuks arenduskomplekt: hoolikalt lukustatud ja räsiga kaitstud, aga arendusotsuste tegemiseks korduvalt kasutatud.

Mida see minu 86,1 protsendiga teeb

Ei tähenda, et number oleks võltsitud. Tähendab, et number vastab teisele küsimusele, kui ma arvasin.

Küsimus	Kas 86,1% vastab sellele
Kas mudel läks paremaks nendes asjades, mida ma sihtisin?	Jah. Baasmudel 61,7 sama mõõduga. Tõus on tõeline.
Kas see on erapooletu hinnang mudeli eesti keele oskusele?	Ei. Number on optimeeritud selle mõõdu peale. Ta on ülespoole kallutatud ja kalde suurust ma ei tea.
Kas seda tohib võrrelda GPT, Gemini ja Claude'i tulemustega?	Ettevaatlikult. Nema said sama testi külmalt, mina olen selle peale kolmteist ringi häälestanud. Võrdlus on minu kasuks kallutatud, ja test ise on üles ehitatud minu baasmudeli vigade peale.

Kuidas ma seda ruumis ütlen, sõna-sõnalt: "86,1 protsenti on arendusmõõt, mitte sõltumatu tulemus. Ma optimeerisin selle mõõdu vastu kolmteist ringi, nii et ta on ülespoole kallutatud. Mul on üks osaliselt sõltumatu kontroll: 378 käänamislahtrit, mida treening ei näinud, ja seal on tulemus umbes kümme punkti madalam. Päril sõltumatut pimehindamist ei ole tehtud ja seda ma teie käest tegelikult tulen küsima."

Kuidas oleks õige teha

1. Jaga kolmeks juba alguses. Ehita korraga kaks ülesandekomplekti sama retsepti järgi, ja pane teine kohe kinni. Mitte "ma vaatan seda hiljem", vaid päriselt kinni.
2. Häälesta ainult valideerimiskomplekti vastu. Kõik ringid, kõik otsused, kõik võrdlused käivad selle peal.
3. Ava test üks kord, päris lõpus. Kui number on halb, ei tohi minna tagasi treenima ja siis uuesti mõõtma. See oleks sama viga uuesti, ainult aeglasemalt.
4. Kui pidid siiski mitu korda vaatama, ütle mitu. Aus number koos "vaatasin kolmteist korda" on rohkem väärt kui puhas number ilma selleta.

Mis mul selle asemel on, ja mis päästab töö ära. Ma ei jäänud päris ilma sõltumatu mõõduta, kuigi ma seda alguses ei planeerinud. Kolm asja mõõdeti väljastpoolt minu ringi: perpleksus kõrvale pandud tekstil, mille žanrid olid samad, aga tekstid teised; 378 käänamislahtrit, mida ükski treeninguannus ei näinud; ja kolm avalikku testi (MMLU eesti keeles, EstQA, HumanEval), mida ma ei ehitanud ja mille vastu ma ei häälestanud. Need on kitsamad kui päris pimetest ja ükski neist ei kata kogu eesti keele oskust, aga metodoloogiliselt on nad sõltumatud: nad ei ole minu ringi sees. Kui ma pean ühe numbri valima, mida ruumis ette näidata, siis ma valin perpleksuse 22,2 → 15,4, mitte 86,1.

Mida vana komplektiga edasi teha

Seda ei pea ära viskama, ja see on tähtis, sest ma kulutasin selle peale nädalaid. Ta saab lihtsalt uue nime ja uue töö: regressioonitest. See tähendab püsivat kontrolli, mis ütleb, kas uus mudeliversioon rikkus midagi, mis varem töötas. Selleks on ta väga hea, sest tal on terve katseajalugu taga. Ta lihtsalt ei ole see, mille pealt lõpptulemust kuulutada.

Kui number läheb slaidile, käib kõrvale lause. Samas kirjasuuruses, mitte joonealuses märkuses:

86,1% arenduskomplektil (151 ülesannet) iteratiivselt optimeeritud, 13 ringi sõltumatu pimetest tegemata

Kuidas ma seda ütlen, kui keegi küsib otse

"Meie fikseeritud 200 ülesandega kogumis oli automaatselt hinnatava osa lähtekoht 61,7 protsenti ja arendusprotsessi lõpus 86,1. Pean siin parandama oma varasemat nimetust: see ei ole sõltumatu testitulemus. Ma vaatasin sama mõõtu pärast igat ringi, valisin selle järgi nõrku kategooriaid ja koostas nende järgi järgmisi annuseid. Nii et see on arendusmõõt. Ta näitab, et ma suutsin mudelit selle mõõdu järgi märkimisväärselt paremaks häälestada. Ta ei tõesta sama suurt paranemist uutel, sõltumatutel ülesannetel. Aus lõppjärelendus ootab puutumata pimetesti, eelistatavalt teie või mõne teise sõltumatu hindaja käes."

Ja miks see vahe ikkagi ei ole mõttetu. Kolm asja jäävad kehtima ka pärast kogu seda möödumist. Esiteks: treeningu- ja mõõtmistorustik töötas: mudeli käitumist sai sihitud suunas muuta, ja see ei ole iseenesestmõistetav. Teiseks: just see komplekt näitas mulle kätte konkreetsed puudused, näiteks üksiksõna ja fraasi vahe, mida ma muidu poleks leidnud. Kolmandaks: signaal on piisavalt suur, et korralik sõltumatu katse tasuks ära. Nõrk tulemus ei annaks isegi selleks põhjust.

Milline oleks õige järgmine katse

1. Külmuta praegune mudel, retsept ja kõik otsustusreeglid.
2. Anna sõltumatule koostajale võimekuste kirjeldus, aga mitte olemasolevaid ülesandeid.
3. Lase koostada uus pimetest uute lemmade, mallide ja tekstidega.
4. Jooksuta samade seadistustega läbi neli asja: baasmudel, puhas CPT-mudel, lõplik mudel ja võrdlusmudelid.
5. Lase inimhinnangut vajavad vastused hinnata vähemalt kahel pimedal hindajal.
6. Avalda punkti hinnangud, nimetajad JA usaldusvahemikud.
7. Ära muuda mudelit selle tulemuse põhjal enne, kui tulemus on välja öeldud.

Ja siis kordub sama küsimus uuesti. Pärast avaldamist võib pimetestist saada järgmise versiooni arenduskomplekt, aga siis on vaja jälle uut puutumata testi. Sõltumatus ei ole faili igavene omadus, see on protsess, mida tuleb iga kord uuesti üleval hoida. Just sellepärast on see peatükk materjalis olemas: see viga ei ole ühekordne, see on selline, mida tehakse iga projekti juures uuesti.

6.3. Kolm eri asja, mida mõõta

Mõõt	Mida ütleb	Mida EI ütle
Ülesandetest (meie 200)	Kas mudel oskab konkreetseid asju: käänata, parandada, vormistada.	Kas ta kõlab loomulikult; kas vestlus toimib

Mõõt	Mida ütleb	Mida EI ütle
Perpleksus (perplexity)	Kui hästi mudel oskab ennustada tokeneid selles konkreetses tekstis. Erinevalt ülesandetestist ei nõua ta vastamist, seega mõõdab keelt ka siis, kui mudel juhiseid ei järgi.	Ei ole "keeletaju mõõt". Ta sõltub tükeldajast ja tekstivalikust ega võrdu grammatilisuse ega loomulikkusega
Inimhindamine	Kas vastus on päriselt hea. Ainus, mis mõõdab loomulikkust.	Ei skaleeru; aeglane ja subjektiivne

Perpleksuse kohta kaks reeglit, mis hoiavad sind ruumis hädast eemal. Esiteks: perpleksust tohib võrrelda ainult siis, kui tükeldaja on sama ja tekst on sama. Kahe eri mudeli perpleksuse arvud ei ole võrreldavad, kui nende tükeldajad erinevad, ja peaaegu alati nad erinevad. Minu 22,2 → 15,4 on aus, sest see on sama mudel enne ja pärast, samal tekstil. Teiseks: mina mõõtsin ainult ühel žanril (toimetatud proosa, kust CPT-korpus tuli). Kas uudistekeeles, ametikeeles või kõnekeeles läks ka paremaks, ma ei tea. See on üherealine katse, mis on tegemata.

Meie aus puudujääk: 47 ülesannet meie testist nõuavad inimhinnangut ja on siiani hindamata. Kõige huvitavamad vead leidsime mudeliga vesteldes, mitte testiga. Automaatika ei näinud neid.

Ja üks number, mille ma pean täpselt paika panema, sest kaks eri ülevaatajat leidsid, et minu paberil see ei klapi. Testis on 200 ülesannet. Neist 47 on märgitud inimhinnangut nõudvaks. 200 miinus 47 on 153, aga minu skoor on arvatud 151 pealt. Läksin skoorijasse vaatama ja leidsin põhjuse: kaks ülesannet on regressioonikontroll koodis (kirjuta Pythonis funktsioon) ja need on küll märgitud automaatselt kontrollitavaks, aga skoorija jätab nad teadlikult vahele, sest töötava koodi õigsust ei saa stringivõrdlusega hinnata. Nii et õige jaotus on:

200 ülesannet kokku - 47 vajavad inimhinnangut (rubriik) - 2 koodiülesanded, mida stringivõrdlus ei hinda = 151 automaatselt skooritud 86,08% = 129,98 punkti / 151 ülesannet

Väike asi, aga just seda tüüpi asja peab ette kandev inimene teadma peast. Kui sa ei oska öelda, mis on su nimetaja, ei usu keegi ka su lugejat.

6.4. Tuntud avalikud testid

Neid tasub nimepidi teada, sest neid mainitakse igal pool:

MMLU: lai üldteadmiste test valikvastustega (ajalugu, meditsiin, õigus, matemaatika). Eesti keelde tõlgitud versioon on olemas, meie kasutasime seda.

HumanEval: programmeerimine: kirjuta funktsioon, mis läbib testid. Mõõt on pass@1: mitu protsenti läks esimese katsega õigeks.

EstQA: eestikeelne lugemisülesanne: leia vastus tekstist. Mõõdud on F1 (kui palju kattub) ja EM (kas täpselt sama).

EKI mõõdupuu: Eesti Keele Instituudi enda võrdlus, kus mõõdetakse muu hulgas keelenõu, idioome, terminoloogiat ja propagandakindlust.

6.5. Statistiline rangus: koht, kus me jäime puudu

Kolm asja, mida tõsine töö nõuab ja mida meil ei ole:

1. Mitu seemet. Treeningus on juhuslikkust. Kui jooksutad sama asja näiteks kolm korda eri seemnetega ja saad kolm eri tulemust, siis tegelik number on nende keskmine koos hajuvusega. Meil on üks jooks.

2. Usaldusvahemik. "86,1 protsenti" ei ütle midagi, kui ei ole teada, kui palju see kõiguks kordamisel.
3. Piisav valim. Meie väikseimad kategooriad on 7 ülesannet, üks vastus tähendab 14 protsendipunkti. Sellised kõikumised ei ole tõlgendatavad.

See on hea koht ettekandes. Kui sa ise ütled välja, mis on su töös nõrk, ei ole kellelgi vaja seda sinu vastu kasutada, ja akadeemilises ruumis on see märk sellest, et sa tead, mida teed.

6.6. Mudeli enda vead kui mõõt ja kui materjal

See on meie kõige omanäolisem võte ja see, mille vastu ruumis tõenäoliselt kõige rohkem huvi tuntakse.

1. Genereeri hulk ülesandeid, mille õige vastuse sa tead (meil Vabamorfis sünteesitud käändevormid).
2. Lase mudelil vastata.
3. Kontrolli vastused automaatselt (morfoanalüsaatoriga).
4. Vead on korraga: (a) veakaart, mis näitab, kus mudel eksib, ja (b) järgmise treeninguringi materjal.
5. Treeni, mõõda uuesti, korda.

Selle tsükli ilu on selles, et ta ei vaja peaaegu üldse käsitsitööd. Aga ma kirjutasin mustandis, et ta "ei vaja inimest ega välist andmestikku" ja et "mudel toodab ise oma õppematerjali", ja see on oma kirjelduse järgi vale. Vaata sammu 1 ja sammu 3 uuesti: õiged vormid tulevad Vabamorfist, ülesanded tulevad generaatorist, ja kontroll käib morfoanalüsaatoriga. Need kõik on välised ja inimeste tehtud.

Täpne sõnastus: mudel toodab oma vead, mitte usaldusväärseid õigeid vastuseid. Tsükel töötab ainult sellepärast, et on olemas väline oraakel: miski, mis teab õiget vastust ja mille vastu mudeli oma vastust võrrelda. Eesti keeles on selleks Vabamorf. Selle vahe teadmine on tähtis kahel põhjusel: esiteks ei saa seda meetodit üle kanda valdkonda, kus oraaklit ei ole; teiseks päris nii, nagu ma kirjutasin, näeks see välja igiliikurina, ja igiliikureid ei ole.

6.7. Kuidas teada, MIS aitas: kontrollkatse

Treeningu järel on lihtne näha, et tulemus muutus. Palju raskem on teada, miks. See on peatükk, mille puudumine on minu töö kõige suurem sisuline nõrkus pärast eelmist.

Analoogia ärimaailmast, mis on täpselt sama loogika. Kui ettevõtte muudab samal kuul hinda, reklaami ja müügimeeste tasustamist, ja käive kasvab, siis mida ta teab? Ta teab, et pakett töötas. Ta ei tea, milline osa paketist töötas, ega isegi seda, kas mõni osa hoopis kahjustas ja teised kompenseerisid. Mudelitreeningul kehtib see sama, ainult et muutujaid on rohkem.

Katset, kus üks koostisosa võetakse ära või asendatakse ja vaadatakse, mis muutub, nimetatakse ablatsiooniks (ablation). Nimi tuleb mõttest "eemalda üks osa".

Põhjuslik väide vajab kontrolltingimust ja muus osas võrreldavaid katseid. Kui ma tahan öelda "kordus hoidis koodioskuse alles", peab mul olema kaks muus osas ühesugust jooksu: üks korduseta, teine kordusega. Mul ei ole. Nii et mul ei ole seda väidet.

Minimaalne katsemaatriks, mis minu kõik lahtised küsimused sulgeks:

Küsimus	Kontroll	Katse	Mis peab võrdne olema
Kas iteratsioon ise aitab?	Kõik andmed ühe jooksuna	Samad andmed 13 ringis	Tokenid, sammud, õpisammu kogusumma, lähtepunkt

Küsimus	Kontroll	Katse	Mis peab võrdne olema
Kas vigade järgi valimine aitab?	Ette määratud andmejaotus	Sama mahuga veapõhine valik	Maht, vorming, sammud
Kas kordus aitab?	0% kordust	3% (CPT) või 15-18% (SFT)	Kogu tokenieelarve ja ülejäänud andmestik
Kas rank 32 on parem?	Rank 16	Rank 32	Sihtmoodulid, alpha skaala, sammud, andmed, õpisammu otsing mõlemale
Kas CPT mõju tuleb just proosast?	Sama maht muud eesti teksti	Toimetatud proosa	Tokenid ja kõik treeningseaded
Kas Q4 ise rikub mudeli?	Liidetud F16 või Q8	Mitu eri Q4 kvantijat	Mall, lähtefail, test ja server

Mida teha, kui eelarvet nende katsete jaoks ei ole. See on minu olukord ja ilmselt paljude oma. Vastus ei ole "tee katse ikkagi" ega "jäta väide välja". Vastus on sobita väite tugevus tõendi tugevusega:

Ütle: "See juhtus pärast korduse lisamist, aga ma ei isoleerinud korduse mõju." Ära ütle: "Kordus põhjustas selle tulemuse." Kogu retsepti kohta tohib öelda: "See iteratiivne protsess andis parema tulemuse kui minu ühe annuse lähtekatse."

Viimane lause on aus ja endiselt väärtuslik. Ma ei kaota midagi peale vale enesekindluse.

Juhuslikkuse seeme. Tulemust mõjutavad andmete järjekord, algväärtused, juhuslik väljalülitus (dropout) ja mõnikord isegi videokaardi arvutusjärjekord. Seeme on algväärtus, millega püütakse sama juhuslikku protsessi korrata. Üks seeme annab ühe vaatluspunkti. Väike vahe kahe meetodi vahel võib täiesti vabalt tulla ainult juhusest. Tähtsad võrdlused vajavad vähemalt kolme seemet, ja raporteerida tuleb keskmine koos hajuvusega, mitte parim jooks. Minu kõik võrdlused on ühe seemnega (20260822).

Ette registreeritud otsustusreegel. Kõige odavam ja kõige harvem tehtud asi kogu selles peatükis. Enne lõpptesti pane kirja: milline mudeliversioon testile läheb, mis on põhimõõt, kuidas skoor arvutatakse, mida teha vigaste ülesannetega, ja millal loed hüpoteesi toetatuks. See võtab kümme minutit ja võtab ära kiusatuse valida tagantjärele see mõõt, mis kõige paremini välja näeb. Ma ei teinud seda, ja ilma eelregistreerimiseta ei ole tagantjärele võimalik täielikult eristada, millised otsused olid ette määratud ja millised kujunesid protsessi käigus, mis ongi täpselt see, mille vastu selline reegel kaitseb.

6.8. Jooksumanifest: kuidas keegi teine saab sinu töö korrata

"Kood on avalik" ei tähenda, et katse on korratav. Minu hoidlas on 50 Pythoni-skripti ja 26 ahelakäivitajat. Keegi, kes tahab minu tööd kontrollida, ei saa sealt vastust ühele lihtsale küsimusele: millise täpse käsu, andmete ja seadistusega see mudel sündis?

Selle vastus on jooksumanifest: ühe jooksu saateleht, nagu tehase tootmispartii dokument. Milline tooraine, millised masina seaded, milline tarkvaraversioon, milline väljund. Kirjutan selle siia välja täidetuna, sest tühi vorm ei õpeta midagi, ja sellepärast, et mul seda enne selle materjali kirjutamist ühes kohas ei olnudki.

Minu jätku-eeltreeningu jooks ("cpt1")

Valdkond	Väärtus
Baasmudel	Qwen3.8-27B, arhitektuur qwen3_5, vestlusvariant (vestlusmall olemas), 27,78 mld parameetrit, kohalik koopia
Tükeldaja	Baasmudeliga kaasas, 248 320 tükki, lõputoken < im_end >
Andmed	1 248 706 lõiku, 59,5 M sõna; pakitud 53 821 tüki; kordust 3,1% sõnadest; kõrvale 2000 lõiku perpleksuse jaoks
Pikkus	max_length 2048. Kärpimine: iga pakitud tükk oli ~2900 tokenit ja kärbiti 2048 peale: mudelile jõudis 110,2 M tokenit
Pakkimine	Faili tasandil käsitsi (raamistiku oma ei rakendunud)
LoRA	r=32, alpha=64, dropout=0,0, bias=none, rsLoRA väljas; sihtmoodulid q, k, v, o, gate, up, down
Treenitavaid	159,4 M = 0,574% mudelist. Tähelepanukihid 16 kihis 64-st (arhitektuurist), edasisidekihid kõigis 64-s
QLoRA	4-bitine NF4, bf16 arvutus, gradient checkpointing
Optimeerija	paged_adamw_8bit
Õpisamm	8e-6, koosinus-ajakava, soojendus 2%
Partii	füüsiline 1 × kogumine 16 = efektiivne 16
Treening	1 epohh, 3364 sammu, 35,3 tundi
Seeme	20260828 (treening), 20260822 (hindamine)
Tarkvara	Python 3.14.4, torch 2.13.0+cu132, transformers 5.5.0, trl 0.24.0, peft 0.20.0, unsloth 2026.8.19, bitsandbytes 0.50.1, CUDA 13.2, draiver 595.84
Riistvara	RTX 5090, 32 GB VRAM, võimsuspiir 450 W
Hindamine	et_locked_v1.jsonl, räsi 439a37ee00eb9088..., temperatuur 0,3, top-p 0,9, top-k 40, nimetaja 151

Vaata seda tabelit ja siis vaata, mida ma peatükkides 2.2, 4.5 ja 6.3 kirjeldasin. Kolm minu viga on siin tabelis nähtavad: kärpimine, 3,1% kordus, ja nimetaja 151. Kui ma oleksin selle lehe täitnud enne treeningut, mitte kolm nädalat hiljem, oleksin ma nad kõik kohe leidnud. Manifest ei ole bürokraatia. Ta on odavaim olemasolev veapüüdja.

Kaks asja, mis manifestist tavaliselt puudu jäävad ja mida minult ruumis küsitakse

1. Kui suur adapter tegelikult oli. "LoRA rank 16" ei ütle seda. Sama rank annab täiesti eri suuruse, olenevalt sellest, kas ta pandi ainult päringu- ja väärtusprojektsioonile või kõigile seitsmele. Raporteeri alati kolm asja: sihtmoodulite nimed, treenitavate parameetrite arv ja osakaal mudelist.
2. Kuidas adapterid kokku said. Kas CPT-adapter liideti baasi sisse enne SFT-d, või treeniti SFT tema peale? Millises täpsuses liideti? Millisest failist tehti lõplik pakend? Mina liitsin CPT-adapteri baasi sisse ja treenisin SFT liidetud mudeli peale, aga ma pidin selle väljaselgitamiseks skripte lugema, mis tähendab, et keegi teine ei oleks seda üldse teada saanud.

Suitsutest. Iga teisenduse järel (liitmine, kvantimine, pakendamine) tuleks lasta läbi väike fikseeritud kontroll, mitte kogu hindamine, vaid viis-kümme viipa, mis ütlevad, kas torustik on tehniliselt terve. Mina ei teinud seda ja maksin selle eest kaks korda: üks kord kvantimisel (Q4 rikkus mudeli) ja teine kord pakendamisel (vestlusmall puudus, mudel hakkas kajama). Mõlemad oleksid

6.9. Kas me mõõdame eesti keelt või kooskõla ühe tööriistaga?

See on peatükk, mille pean EKI-s ise avama, sest selles ruumis on inimesi, kes tunnevad Vabamorf minust põhjalikumalt. Kui ma ei ütle seda ise, ütleb keegi teine, ja siis on see minu vastu, mitte minu poolt.

Lähtekoht: hindamissüsteem on ise mõõteriist. Kui termomeeter on valesti kalibreeritud, ei päästa olukorda see, et näit kuvatakse kolme komakohaga. Minu 86,08 on kahe komakohaga näit.

Vabamorf on väga kasulik, aga ta ei ole eksimatu

Vabamorf oskab eesti sõnavorme analüüsida (mis vorm see on) ja sünteesida (anna mulle selle sõna mitmuse osastav). Just see teine oskus tegi võimalikuks kogu minu töö: ma sain automaatselt luua kümneid tuhandeid ülesandeid, mille õiget vastust ma tean. Käsitsi poleks ma neid iial teinud.

Aga tal on oma sõnastik, oma reeglid, oma versioon ja oma piirid. Ta võib mitte tunda uut sõna või pärisnime; anda ühele vormile mitu analüüsi; eelistada normingulist vormi, kuigi kasutuses on teisigi; sünteesida vormi, mis on tehniliselt võimalik, aga kontekstis ebaloomulik; jätta mõne rööpvormi esitamata; või lihtsalt eksida. Tema väljundit ei tohi käsitleda absoluutse tõena ilma valimit käsitsi üle vaatamata. Mina vaatasin valimit, aga ma ei dokumenteerinud, kui suurt ega kui süstemaatiliselt.

Ringhindamise oht: kõige tõsisem asi selles peatükis

Kui ülesanded luuakse ühe morfoloogilise süsteemiga ja vastuseid hinnatakse sama süsteemiga, siis mida test tegelikult mõõdab? Ta mõõdab mudeli kooskõla selle süsteemi analüüsiga. See on kasulik asi, aga see on kitsam kui "eesti keele oskus".

Analoogia. Kui õpetaja koostab kõik eksamiküsimused ühe õpiku järgi ja kontrollib vastuseid sama õpiku vastustelehega, siis eksam mõõdab suurepäraselt selle õpiku käsitlust. Ta ei pruugi katta kõike, mis keeles lubatud on. Õpilane, kes vastab teise, samuti õige variandiga, saab valesti.

Ja see ei ole minu jaoks hüpoteetiline, see juhtus. Mu mõõteriist luges pikka aega valeks vormid, mis olid tegelikult õiged, sest ta tundis ainult üht varianti. Eesti keeles on rööpvorme rohkem, kui automaatne hindaja arvab. Kui ma selle parandasin, tõusis skoor korraga, ilma et mudel oleks üldse muutunud. Osa minu "paranemisest" oli tegelikult mõõteriista paranemine, ja seda kahte on tagantjärele raske lahku harutada.

Mitmetähenduslikkus

Üks kirjaipilt võib saada mitu analüüsi. Vorm "tee" võib olla nimisõna (maantee) või tegusõna (tegema). Ilma kontekstita võib ülesanne olla lahendamatu, ja siis ei mõõda ta mudelit, vaid ülesande halba koostamist. Iga ülesande juures tuleks otsustada: kas õige vastus on üks vorm või vormide hulk; kas konteksti on piisavalt; kas hinnatakse normingut või tegelikku kasutust; ja kas suurtäht, kirjavahemärk või lisatud selgitus mõjutavad skoori.

Veataksonoomia: õige-vale ei ütle, mida mudel ei oska

Kui sul on ainult protsent, ei tea sa, mida parandada. Vead tuleks jagada vähemalt nendeks liikideks, ja pane tähele, et kaks viimast ei ole üldse mudeli vead:

vale kääne · vale arv · vale tüvi · astmevahelduse viga · ühildumisviga · rektsiooniviga · õigekirjaviga · ülesande valestimõistmine · õige vorm koos keelatud lisatekstiga · aktsepteeritav rööpvorm, mida hindaja ei tundnud · hindamisvahendi viga

Just need kaks viimast eristavad mudeli viga mõõteriista veast. Ilma selle eristusega parandad sa mudelit seal, kus katki oli hoopis mõõt.

Inimhindamine: kuidas see õigesti käib

Loomulikkust, sidusust ja stiili ei mõõda ükski automaat. Selleks on vaja inimesi, ja siis on vaja protokoll, muidu on tulemus arvamus. Hea protokoll sisaldab: vähemalt kaks sõltumatut hindajat; pimedat hindamist, kus mudeli nimi ei ole näha; juhuslikustatud vastuste järjekorda; selget hindamisjuhendit; harjutusvooru; hindajate kokkuleppe mõõtu; ja reeglit, mida teha, kui hindajad ei nõustu.

Hindajate kokkulepe on omaette tulemus. Kui kaks pädevat inimest on sageli eri meelt, ei tohi esitada skoori nii, nagu õige vastus oleks iseenesest ilmne. See on tegelikult huvitav leid omaette, mitte tüütus.

Minu seis: 47 ülesannet ootavad inimhindamist ja süstemaatilist sõltumatut inimhindamist ei ole tehtud. Ise olen vastuseid vestluses ja valimina hinnanud, aga see ei ole protokoll. See on koht, kus mul on väga vähe pakkuda ja teie asutuses on seda oskust rohkem kui kusagil mujal Eestis. Ma tulen sellega ruumi teadlikult puuduliku poolena, mitte lünka peites.

VII osa. Riistvara ja pakendamine

7.1. VRAM: mis mahub

VRAM on videokaardi oma mälu. See on esimene number, mis otsustab, kas sa saad mudelit üldse jooksutada. Sinul on 32 GB (RTX 5090).

Mustandis kirjutasin "ainus number" ja see ei pea paika. Kõrval on vähemalt viis asja, mis samamoodi otsustavad, ja ma jooksin igaühe otsa: kas kaart toetab neid andmetüüpe ja tuumasid, mida teek nõuab (minu 5090 on nii uus, et iga teek pidi olema uue CUDA peal ehitatud, muidu tuli "no kernel image available"); kui palju on tavamälu väljakolimiseks; kui pikk on kontekst, sest vestluse vahemälu kasvab pikkusega; milline on arhitektuur; ja kas draiver ja raamistik seda mudelit üldse tunnevad. VRAM ütleb, kas mudel mahub. Ülejäänud ütlevad, kas ta ka töötab.

Mudeli suurus	Kasutamiseks (4-bit)	QLoRA treeninguks	Täistreeninguks
7-8 miljardit	~5 GB	~10 GB	~60 GB
13-14 miljardit	~9 GB	~16 GB	~110 GB
27 miljardit	~17 GB	~26 GB	~220 GB
70 miljardit	~40 GB	~48 GB	~560 GB

Numbrid on ligikaudsed ja sõltuvad kontekstiakna suurusel. Meie jätku-eeltreeningul oli tippkasutus 29 GB 32-st, päris piiril.

7.2. Kiirus ja ajaarvestus

Meie mõõdetud arv, mida tasub meelde jätta: 27 miljardi parameetriga mudel QLoRA-ga ühel RTX 5090-l 450-vatise piiranguga töötleb umbes 870 tokenit sekundis.

Sellest saab arvutada iga töö kestuse, ja see arvutus on ühtlasi kontroll, mis päästab sind vaikselt eest:

$110,2 \text{ M tokenit} \div 870 \text{ tok/s} \div 3600 = 35,2 \text{ tundi}$ (mõõdetud: 35,3) Kust 110,2 M tuli: 3364 sammu $\times$ 16 kuhjast $\times$ 2048 tokenit

Mustandis oli siin 131 miljonit ja siis ei klappinud midagi: $131 \div 870 \div 3600$ annab 41,8 tundi, aga mõõtsin 35,3. Ma kirjutasin seletuseks, et "osa arvutusest kattus", mis on udu, kui 870 on juba mõõdetud läbilaskevõime, ei kattu midagi. Õige seletus oli, et kaks arvu räägivad eri asjadest: 131 (õigemini 141) miljonit oli korpuses, 110,2 miljonit jõudis mudelini. Vahe kadus kärpimisel, vt 2.2 ja 4.5.

Kui ma peaksin selle materjali ühe rea peale kokku võtma: kontrolli, kas su tokenite arv, sammude arv ja kellaaeg räägivad ühte juttu. Kui nad ei räägi, on kuskil vaikne viga, ja kolmest arvust kaks on tavaliselt õiged.

Võimsuspiirang. Mõõtsime kolm seadistust, sama töö peal:

Piir	Sekundit sammu kohta	Temperatuur	Energia sammu kohta
575 W (tehase)	8,77	78 °C	5043 J
500 W	10,00 (+14,0%)	73 °C	5000 J
450 W (valitud)	10,59 (+20,7%)	70 °C	4766 J

Kaks vastuintuitiivset asja siin tabelis. Esiteks: 500 W ei säästa energiat (5000 vs 5043 J), pikem aeg sööb madalama võimsuse täpselt ära. Kaotad kiirust ja võidad ainult temperatuuri. Teiseks: aeglustus on ligi lineaarne, mitte tüüpiline mittelineaarne GPU-kõver: 21,7% väiksem võimsuspiir pikendas sammu kestust 20,7% (läbilaskevõime langus on 17,2%). Minu esialgne hinnang oli 8–12% ja see oli lihtsalt vale, QLoRA-treening ei käitu nagu mäng ega renderdus.

Ja üks lause, mille ma pean välja võtma. Kirjutasin, et valisin 450 W, "sest kaart elab kauem". Seda ma ei mõõtnud. Mõõtsin kaheksa kraadi madalamat temperatuuri ja kuulsin, et ventilaator on vaiksem. Et madalam temperatuur pikendab elektroonika eluiga, on üldteada seaduspära, mitte minu tulemus, ja ma ei tea, kui suur see vahe selle kaardi puhul on. Õige sõnastus: valisin 450 W müra ja temperatuuri pärast, kiiruse teadliku hinnaga.

7.3. Kvantimine kasutamisel

Treeningu järel tuleb mudel pakendada. Levinud vorming on GGUF (llama.cpp ja Ollama kasutavad seda) ja seal valitakse tihendusaste:

Aste	27B mudeli suurus	Kvaliteet
Q4_K_M	~17 GB	Hea üldjuhul, aga meie katses halvenes väljund
Q6_K	~21 GB	Peaaegu kadudeta. Meie valik.
Q8_0	~28 GB	Sisuliselt kadudeta, aga suur
F16	~54 GB	Originaal, ei mahu kaardile

Meie leid, mida mujal harva mainitakse: pärast jätku-eeltreeningut tõi Q4 tihendamine tagasi ortograafiavead, mis olid treeninguga ära parandatud. Q6 juures neid ei olnud. Ettevaatust põhjusega: ma ei korranud seda mitme kvantijaga ega mitme seemnega, nii et ma ei tea, kas põhjus oli kvantimine ise või midagi teisendusahelas. Soovitus jääb siiski: kui oled teinud CPT, kontrolli pakendamise mõju eraldi üle, sest see on odav kontroll.

7.4. Serveerimine

Ollama: lihtsaim viis kohalikult jooksutada, üks käsk. Meie kasutame seda.

llama.cpp: mootor Ollama all, annab rohkem kontrolli.

vLLM: serveripoolne lahendus, kui vaja teenindada paljusid kasutajaid korraga. Palju kiirem läbilaskevõime, aga vajab rohkem mälu.

text-generation-inference: sarnane, Hugging Face'i oma.

Praktiline lõks, mis meil juhtus: GGUF-ist mudelit luues ei kandu kaasa vestlusmalli kirjeldus. Ilma selleta saab mudel toore teksti ja käitub katkiselt, kuigi mudel ise on terve. Ollamas tuleb see eraldi ette anda (read RENDERER ja PARSER).

VIII osa. Maastik: mudelid, tööriistad, andmed

8.1. Avatud mudeliperekonnad

"Avatud" tähendab, et kaalud on alla laaditavad. Litsentsid erinevad ja seda tuleb alati kontrollida.

Perekond	Kes teeb	Iseloom
Qwen	Alibaba	Tugev mitmekeelsus, Apache 2.0, palju suurus. Meie valik.
Llama	Meta	Väga levinud, tohutu kogukond, oma litsents (mõned piirangud)
Mistral / Mixtral	Mistral AI	Euroopa, tõhusad, osa MoE-arhitektuuriga
Gemma	Google	Väiksemad suurused, hea kvaliteet, oma litsents
EuroLLM, Viking, Poro	Euroopa koostööprojektid	Ehitatud teadlikult Euroopa keeltele, sh eesti keelele

Miks meie valisime Qweni: Apache 2.0 litsents (lubab kõike, ka avaldamist), 27 miljardit mahub tihendatult ühele kaardile, ja tema eesti keele lähtetase oli mõõtes parim nendest, mida katsetasin. Ütle ruumis ka teine pool: metoodika ei sõltu mudelist: sama torustiku saab järgmise baasmudeli peale jooksutada, ja see ongi mõte.

8.2. Tööriistad

Tööriist	Milleks
transformers (Hugging Face)	Põhiteek: mudelite laadimine ja jooksutamine. Kogu ökosüsteemi alus.
PEFT	LoRA ja teised parameetritõhusad meetodid.
TRL	Treeningu kõrgem kiht: SFT, DPO ja teised. Meie kasutasime.
Unsloth	Optimeeritud treening ühel kaardil: kiirem ja väiksema mälukuluga. Meie kasutasime.
bitsandbytes	4- ja 8-bitine tihendamine treeningul (QLoRA taga).
axolotl	Konfiguratsioonifailipõhine treeningraamistik, kui ei taha koodi kirjutada.
llama.cpp	Teisendamine GGUF-i, kvantimine, jooksutamine.
EstNLTK / Vabamorf	Eesti morfoloogia analüüs ja süntees. Meie torustiku selgroog.

8.3. Kust andmeid saab

Rahvusvahelised: Hugging Face Datasets (kümned tuhanded andmestikud), Common Crawl ja sellest puhastatud kogud (FineWeb, HPLT), Vikipeedia tõmmised (dumps).
Eesti: Tartu Ülikooli koondkorpus (CC-BY-SA), TalTechi avaldatud andmestikud Hugging Face'is, Riigi Teataja avaandmed (autoriõigusega kaitsmata), Riigikogu stenogrammide API, ERR-i

avaldatud kogud, Rahvusraamatukogu vaba juurdepääsuga korpus, Eesti Keele Instituudi kogud (kokkuleppel).

Oluline vahe. Veebist kraabitud tekst (Common Crawl jt) on odav ja hiiglaslik, aga must: reklaamid, korduvad menüüd, masintõlge. Toimetatud tekst (raamatud, ajakirjandus, teadus) on kallis ja väike, aga puhas. Meie mõõtmised näitasid selgelt, et loomulikkuse jaoks on toimetatud tekst asendamatu, sellepärast on EKI ja Rahvusraamatukogu kogud meie jaoks nii tähtsad.

IX osa. Mida ühe kaardi tööst saab üle kanda

See on küsimus, mida sinult ruumis peaaegu kindlasti küsitakse, sest seal istuvad inimesed, kes mõtlevad suurte projektide peale. Vastus on: osa kandub üle täielikult, osa üldse mitte, ja vahe teadmine on täpselt see, mis teeb sinu kogemuse neile kasulikuks. Ausus selle piiri juures on tähtsam kui iga tulemus.

9.1. Mis kandub üle täielikult

Need on andmete ja meetodi õppetunnid. Nad ei sõltu riistvarast ega mudeli suurusest, sest nad räägivad sellest, kuidas õppimine põhimõtteliselt käib.

Õppetund	Miks see skaleerub
Treeningnäite kuju peab vastama kasutuse kujule	See on õppimise loogika, mitte arvutusvõimsuse küsimus. Sada miljardit üksiksõna ei õpeta ikkagi fraasi ühildumist, kui fraasi pole näidatud.
Väike sihitud annus võib suure üldise	Suurel projektil on sama probleem, ainult teises mastaabis: mida rohkem üldist materjali, seda rohkem lahjeneb see, mis on tegelikult vajalik.
Mudeli enda vead on parim materjal	See on tsükel, mitte ressurss. Suurel projektil töötab see paremini, sest ta jõuab rohkem vigu koguda ja kiiremini läbi töötada.
Mõõt tuleb ehitada enne treeningut	Mida suurem projekt, seda kallim on treenida ilma mõõduta. Meil maksis vale mõõt kaks päeva; suurel projektil maksaks sama viga kuu.
Testi tuleb hoida arenduskomplektist lahus	See on puhas metodoloogia ja ei sõltu millestki. Suurel projektil on hind isegi suurem, sest sinna vaatab rohkem inimesi ja iga vaatamine kannab infot edasi. Meie tegime siin oma kõige tõsisema vea (6.2).
Põhjuslik väide vajab võrdluspaari	Ablatsioon on sama loogika igas mastaabis. Suurel projektil on see kallim, aga just seal on ka kõige rohkem korraka muutuvaid asju, mille mõju keegi hiljem eraldi teada tahab.
Jooksumanifest, mitte skriptikaust	Mida rohkem inimesi, seda rohkem seda vaja on. Meie kaustas on 76 faili ja ükski neist ei vasta küsimusele, millise seadistusega avaldatud mudel sündis.
Rööpvormid ja mõõtmisvead	Puhtalt keeleline probleem. Iga eesti keele mudelit hindav süsteem, olgu ta kui suur tahes, alahindab mudelit, kui loeb õigeks ühe variandi.
Leke tuleb blokeerida kirje tasandil	Suurte korpusjuures on leke isegi tõenäolisem, sest keegi ei jõua käsitsi kontrollida, mis sinna sisse sattus.
CPT annab keele, SFT annab oskused	See on faaside tööjaotus, mis kehtib igas mastaabis. Meie mõõtsime seda juhuslikult, kui puhas CPT-mudel osutus heaks jutustajaks, kes ei osanud käänata.
Litsentsi- ja allikapraktika	Suurel projektil on see hoopis kriitilisem, sest tulemus avaldatakse ja seda kontrollitakse.

9.2. Mis El kandu üle

Siin tuleb olla range, sest just siin tekib kiusatus üldistada rohkem, kui andmed lubavad.

Hüperparameetrid. Meie õpisamm $2e-5$ kehtib meie mudelile, meie adapteri suurusele ja meie partiile. Suuremal mudelil ja suuremal partiil on optimaalsed väärtused teised. Neid ei saa kopeerida, ainult lähtekohaks võtta.

LoRA ja rank. Kogu meie arutelu rank 16 vs 32 kohta on olemas ainult sellepärast, et me ei saanud täistreeningut teha. Suurel projektil, kus kõiki kaale saab muuta, on see küsimus olematu.

Kvantimisega seotud leiud. See, et meie Q4-pakendis läks väljund halvemaks, on pakendamise probleem kohalikuks kasutamiseks. Suur projekt serveerib mudelit suures täpsuses ja ei puutu sellega kokku.

Meie absoluutnumbrid. 86,1 protsenti on meie arenduskomplektil, meie mudelil, ja ta on selle mõõdu vastu häälestatud. Ükski teine projekt ei saa seda numbrit endaga võrrelda. Ülekantav on suund, mitte number.

Ja perpleksuse tulemus ei skaleeru nii, nagu ma esimeses mustandis kirjutasin. Ma väitsin, et 31-protsendiline paranemine on suurele projektile ülekantav. See ei ole näidatud. Mida ma näitasin, on see, et üks mudel kohanes ühele tekstijaotusele. Ülekandmiseks oleks vaja mitut mudelisuurust, mitut andmemahutu ja mitut žanri, ehk seda, mida nimetatakse skaleerumiskõveraks ja mida mul ei ole. Aus üldistus on kitsam ja ikkagi kasulik: kümnete miljonite tokenite suurusjärgus toimetatud teksti andis mõõdetava efekti, mis oli mitu korda üle selle läve, mille eksperdid ette pakkusid. See ütleb, et suunda tasub uurida, mitte et tulemus kordub.

Ja üks põhimõtteline piirang. Meie ei muutnud tükeldajat ega mudeli arhitektuuri. Tükeldajat saab muuta, sõnastikku laiendades ja sisend- ning väljundkihti ümber õpetades (1.8), nii et mustandi väide, et selleks peaks mudeli nullist ehitama, oli vale. Aga see on ikkagi töö, mis nõuab tõsist jätku-eeltreeningut ja mis invalideerib kõik varasemad mõõtmised. Meie tööga sinna ei jõua; EKI-suuruse asutuse tööga jõuab.

9.3. Kolm asja, mida väike seadistus annab ja suur ei anna

See on osa, mida tasub ettekandes eraldi rõhutada, sest siin on sinu kogemus suurele projektile päriselt kasulik, mitte lihtsalt sümpaatne.

1. Kiirus, mis lubab katsetada

Meie ring kestis kaks kuni kolm tundi. See tähendab, et üheksa päevaga sai teha 34 treeningjooksu ja iga jook sai vastuse enne, kui järgmine algas. Suur projekt, kus üks jook võtab nädalaid ja maksab kümneid tuhandeid, teeb terve projekti jooksul ehk kolm või neli tõsist katset.

Tagajärg: meie mõõtsime asju, mida suur projekt ei jõua mõõta. Näiteks seda, et sama andmehulk ühe annusena andis 76,5 ja kolmeteistkümne ringina 85,3. Selle katse tegemiseks pidi kaks korda kogu tee läbi käima. Suurel projektil on täismahus korduskatse kordades kallim ja seetõttu palju harvem.

Möönduse ja mõtte vahe. See võrdlus ei ole korralik kontrollkatse: iteratiivses harus koostati andmeid vahepealsete vigade põhjal, nii et seal muutus korraga kaks asja (mitu järku ja sihitud andmed). Nii et number ei tõesta, et "iteratsioon" on see, mis aitas. Aga argument selles peatükis ei sõltugi sellest. Argument on, et väike seadistus lubab sellist katset üldse teha. Suur projekt ei

jõua ka halvasti kontrollitud versiooni teha, sest kogu tee kaks korda läbi käia on seal võimatu.

2. Sundus mõelda enne treenimist

Kui arvutusvõimsust on piiramatult, on lihtne lahendada iga probleem rohkema andmega. Kui sul on üks kaart ja 35 tundi, pead enne küsima, mida sa treenid ja miks. See distsipliin viis meid kõige väärtuslikumate leidudeni: veaanalüüsi, sihitud annusteni, ja lõpuks 130-näitelise mooduli juurde, mis andis rohkem kui mõni kümnetuhandeline.

3. Terviklik vaade

Suures projektis on rollid jagatud: üks inimene kogub andmeid, teine treenib, kolmas hindab, neljas pakendab. Igaüks näeb oma osa. Meie juhtumis käis üks inimene kogu tee läbi, ja just seetõttu tulid välja kohad, mis jäävad rollide vahele:

- Mõõteriist ise oli katki (rööpvormid), seda oleks märganud ainult see, kes nii andmeid kui hindamist vaatab.
- Treeningraamistiku pakkimine ei töötanud vaikselt, seda oleks märganud ainult see, kes ise sammude arvu üle kontrollib.
- Pakendatud mudel läks katki, kuigi treening oli õnnestunud, seda oleks märganud ainult see, kes lõpuks ise mudeliga räägib.

Kõik kolm olid vead, mida ükski üksik etapp poleks avastanud. Nad leiti sellepärast, et keegi vastutas kogu ahela eest.

9.4. Piloodi loogika: kuidas väike katse teenib suurt projekti

Kõige praktilisem viis, kuidas ühe kaardi töö suurt projekti aitab, on eelkatse. Enne kui keegi kulutab nädalaid arvutusaega, saab väikeses mastaabis vastata küsimusele, kas suund üldse tasub.

Meie näide. Küsimus oli: kas toimetatud proosaga eeltreening parandab eesti keele loomulikkust? Eksperdid, kellega nõu pidasin, olid eri meelt: üks ütles, et see on ressursi raiskamine, teine, et tasub proovida kontrollitud piloodina ja mõõta perpleksuse muutust, kusjuures läveks seada 5 kuni 10 protsenti.

Tegime piloodi: 110 miljonit tokenit, 35 tundi, üks kaart. Tulemus oli 31 protsenti, kolm korda üle läve. See vastus maksis pooleteise päeva ja ütleb nüüd igale suuremale projektile, et sellesse suunda tasub investeerida. Ilma piloodita oleks sama vastus maksnud kordades rohkem või jäänud üldse saamata.

Sama loogika kehtib igal pool: andmete koostise valik, faaside järjekord, annuse suurus, uue meetodi tasuvus. Kõik need on küsimused, millele saab väikeses mastaabis vastuse, mis annab suures mastaabis otsustamiseks tõendusmaterjali. Automaatselt see suures mastaabis ei kehti, isegi kui mõõt on aus.

9.5. Kokkuvõte ühe lausega

Riistvara määrab, kui suurt mudelit sa saad treenida. Meetod määrab, kas treenimisest on kasu. Esimeses oleme väikesed ja jääme väikesteks. Teises võib üks hoolikas inimene ühe kaardiga leida asju, mida suur projekt ei jõua otsida, ja need leiud kehtivad ka seal.

X osa. Meie projekt: kõik eelnev rakendatuna

10.1. Lähtekoht ja mõõt

Baasmudel Qwen3.8-27B, riistvara üks RTX 5090. Ehitasime 200 ülesandega lukustatud testi eesti keele nõrkade kohtade peale. Baastulemus 61,7 protsenti. Näide sellest, mis oli katki: küsimusele käänete arvu kohta vastas mudel kord seitse, kord kolmteist, ja loetles sõnu, mida eesti keeles ei ole.

10.2. Kaks rada ja nende ühendamise

Rada	Mida tegime	Tulemus
A: oskused	13 sihitud treeninguringi, iga ring 2-3 tundi. Igas ringis: mõõda → leia nõrgim koht → 300-3000 näidet täpselt sinna → treeni → mõõda uuesti.	61,7 → 85,3%
B: keel	110 miljonit tokenit toimetatud eesti proosat baasmudelisse (35 tundi), siis samad oskused peale.	perpleksus 22,2 → 15,4 arendusmõõt → 86,1%

Miks rada B on tähtsam, kui number ütleb. Vahe 85,3 ja 86,1 vahel on väike. Aga rada B mudel kirjutab teistmoodi. Sama küsimuse peale ("kirjuta lühike lugu tüdrukust, kelle unistus täitub") andis rada A kuiva valemi ("unistused täituvad, kui usud endasse") ja rada B päris loo: külatüdruk leiab keldrikapist katkise teleskoobi, parandab selle ära ja avastab tähistäeva. Seda vahet ükski automaatteest ei mõõda.

Ja kohe kaks mõõndust selle loo juurde, sest see näide on ettekandes mu kõige tugevam ja seetõttu ka kõige rünnatavam. Esiteks: ma ei genereerinud kümmet varianti ega valinud parimat (see oli üks jooks), aga ma ei ole seda ka pimedalt ja mitme hindajaga kontrollinud, nii et see on illustratsioon, mitte mõõtmine. Teiseks, ja see on tõsisem: ma ei ole kontrollinud, kas see lugu on jäädvustatud, kas mudel jutustas midagi omast, või taastas ta midagi väga lähedast mõnele treeningkorpuse tekstile. Kontroll on lihtne (otsi pikki kattuvaid jadasid korpusest, vt 5.8) ja ma pole seda teinud. Kui keegi seda küsib, on aus vastus "hea küsimus, seda ma ei kontrollinud, ja ma kontrollin ära".

10.3. Lõpptulemused

Mõõt	Baas	Meie lõplik	Võrdluseks samal testil
Meie arendusmõõt (151 skooritud ülesannet)	61,7	86,1	GPT 81,7 · Gemini 84,3 · Claude 86,6
Käänamine (60 ülesannet)	51,7	91,7	kõigil kolmel 96,7
Grammatikaparandus (50)	80,2	84,3	GPT 71,1 · Gemini 76,8 · Claude 85,9
Rektsioon (8)	87,5	100	Gemini ja Claude 100
Ilukirjanduse perplexity	22,2	15,4	madalam on parem
EstQA lugemine (F1)	86,9	93,6	Claude 92,4 · Gemini 95,2

Mõõt	Baas	Meie lõplik	Võrdluseks samal testil
MMLU-et üldteadmised	68,7	66,0	Gemini 91,7 · Claude 90,3
HumanEval kood	71,3	85,4*	*möödetud eelmisel versioonil

Viis ausat märkust selle tabeli juurde, mis tuleb kõik ise välja öelda, enne kui keegi neid küsib:

1. Esimene rida on arendusmõõt, mitte sõltumatu test. Ma vaatasin seda kolmteist korda ja häälestasin selle vastu (vt 6.2). Number on ülespoole kallutatud ja kalde suurst ma ei tea.
2. Võrdlus GPT, Gemini ja Claude'iga on konstruktsioonilt minu kasuks: test on ehitatud minu baasmudeli vigade peale ja mina olen selle vastu häälestanud, nemad said selle külmalt. Ma ei fikseerinud ka nende mudeliversioone ja dekodeerimisseadeid nii täpselt, nagu oleks vaja. Aus lugemine: nad on samas suurusjärgus, mitte "ma võitsin GPT-d".
3. MMLU langes 2,7 punkti. Ma ei ole seda korduskatsega kinnitanud, nii et ma ei tea, kas see on päris langus või mõõtemüra.
4. HumanEval mõõdeti teisel mudeliversioonil, nii et seda arvu ei tohi sama veeru teiste ridadega kokku lugeda.
5. Perpleksuse rida näitab jätku-eeltreeningu mõju kõige selgemalt, sest ma ei häälestanud selle vastu ühtegi ringi. Aga ka see ei ole minust päris sõltumatu: korpuse, žanri ja kõrvalepaneku meetodi valisin mina, ja eraldus käis lõigu, mitte teose tasandil (5.8). EstQA, MMLU ja need 378 nägemata käänamislahtrit on samuti minu ringist väljas ja piiritlevad eri võimeid.

10.4. Ajakulu ja maht

Kokku 9 päeva. Jätke-eeltreening 35,3 tundi (3364 sammu, 110,2M tokenit mudelini jõudnud). Oskuste ringid à 2–3 tundi.

Ja siin on üks arv, mille ma pidin samuti üle lugema. Ma kirjutasin "kokku 19 ringi". Kui ma adapterite kausta üle lugesin, oli seal 34 salvestatud treeningjooksu (lisaks üks suitsutest). Jaotus:

Rada	Jookse	Mis need olid
Esimene oskusrada	13	ring1 ... ring13, tulemus 61,7 → 85,3
Eelistusõpe	4	dpo1 ... dpo4, neist enamik ebaõnnestus
Rank 32 võrdlus	4	r32-ring1, r32-ring2, r32-ring4, rank32-solo
Tšempioni rada	4	ts4-sft, ts4-dpo, ts5-sft, ts6-sft
Jätke-eeltreening	1	cpt1
CPT-järgne rada	6	cpt1-sft, cpt1-sft2, cpt1-ring1...3, cpt1-dpo
Lihvimine	2	lihv, lihv2 (lõplik tšampion)

Ma jätan selle tabeli sisse, sest ta ütleb midagi, mida "19 ringi" ei ütle: üle poole jooksudest ei olnud edenemine, vaid katsed, võrdlused ja ebaõnnestumised. Neist 34-st jõudis lõpptulemuseni üks ahel. Kui keegi loeb kokkuvõtet ja näeb ainult sirget joont 61,7 pealt 86,1 peale, on tal vale pilt sellest, kuidas see töö käib.

Andmeid: koondkorpusest ekstraktisime 101,5 miljonit sõna, treeningmiksi läks 59,5 miljonit sõna ehk ~141M tokenit, millest kärpimise tõttu jõudis kohale 110,2M. Käänamiskorpus 13 436 kirjet,

millest avalikult 11 011.

10.5. Mis on avalik

github.com/pertlomp/qwen38-et: 76 skriptifaili, lukustatud test, kõik raportid koos ebaõnnestumistega, kakskeelne kirjeldus.

huggingface.co/pertai/qwen38-et-adapters: kolm adapterit: lõpptšempion, puhas jätku-eeltreeningu keelekiht (eraldi, uurimiseks!), 13-ringilise oskusraja adapter.

huggingface.co/pertai/qwen38-et-27b-GGUF: liidetud täismudel, Ollama-valmis.

huggingface.co/datasets/pertai/eesti-kaanamiskorpus: 11 011 kirjet allika ja litsentsiga.

XI osa. Ausad vastused rasketele küsimustele

Need on küsimused, mida sinult tõenäoliselt küsitakse. Vastused on sõnastatud nii, nagu sa võid neid päriselt öelda. Kus õige vastus on "ei" või "ei tea", on see kirjas, need on kõige tähtsamad.

«Kui te valisite pärast igat ringi testi järgi nõrgima kategooria ja treenisite sinna, siis miks te nimetate seda ikka veel testiks?»

Te olete täiesti õigel jäljel ja ma parandan selle nimetuse ise ära. See ei ole test, see on arenduskomplekt. Testi määratleb see, et teda vaadatakse üks kord, pärast kõiki otsuseid. Mina vaatasin teda kolmteist korda ja tegin iga vaatamise järel otsuse, mida järgmiseks treenida. Ülesanded ise treeningusse ei sattunud, seda ma kontrollisin, aga see ei ole see, mis siin katki läks: katki läks see, et test juhtis treeningu sisu. Nii et 86,1 on arendusmõõt. Ta näitab, et ma suutsin mudelit selle mõõdu järgi paremaks häälestada. Ta ei tõesta sama paranemist sõltumatutel ülesannetel. Puutumata pimetesti ei ole tehtud ja see on täpselt see, mille pärast ma siia tulin.

«Mis täpselt on 86,1 protsendi nimetaja: 151, 153 või 200?»

151. Kogumis on 200 ülesannet. 47 nõuavad inimhinnangut ja on hindamata. Kaks on koodiülesanded, mis on küll märgitud automaatselt kontrollitavaks, aga mille skoorija jätab vahele, sest töötavat koodi ei saa stringivõrdlusega hinnata. Jääb 151, ja 86,08 protsenti on 130,0 punkti 151-st. Osalist punkti antakse grammatikaparanduse kategoorias sõnade kattuvuse järgi, mujal on null või üks.

«Kas 61,7 → 86,1 mõõdab eesti keelt üldiselt või ainult seda kitsast ülesandekomplekti, mida te õpetasite?»

Suure osa ulatuses viimast, ja ma ei suuda praegu öelda, kui suure. Mul on kaks osalist kontrolli. Esiteks 378 käänamislahtrit, mida ükski treeninguannus ei näinud: seal on tulemus umbes kümme punkti madalam. Teiseks perpleksus kõrvale pandud tekstil, mis paranes 31 protsenti ja mis ei sõltu üldse ülesannete kujust. Aga kumbki ei ole sõltumatu koostaja tehtud pimetest. Kui te tahaksite selle teha, oleks see minu jaoks kõige väärtuslikum asi, mis sellest kohtumisest tulla saaks.

«Kas te ei treeninud lihtsalt testi peale?»

Mitte otse, aga tulemus on sarnane, ja ma sõnastan selle täpselt. Ülesande tasandil on leke blokeeritud: testiülesanded ja nende sisusõnad, kokku 1467 sõna, on igast treeninguannusest välja filtreeritud, nii et ükski testiülesanne ei olnud treeningnäide. Aga ma kohendasin mudelit korduvalt sama komplekti kategooriatulemuste põhjal, ja seetõttu ei ole see kompleks enam sõltumatu test. See on eraldi ja üldisem küsimus: mallid, paradigmad ja samad lemmad teistes vormides jäid treeningusse alles, nii et üldistus uutele mallidele on lahtine. Aga täpsel ülesande tasandil on leke tõesti blokeeritud.

«Kas mõõtsite statistilist olulisust?»

Ei. Üks seeme, usaldusvahemikke ei ole, ja väikestes kategooriates (7–9 ülesannet) tähendab üks vastus kuni 14 protsendipunkti. Üksikute kategooriate kõikumisi ei tohi tõsiselt võtta ja ma püüan neid ka ise mitte üle tõlgendada. Üldskoor 151 ülesande peal on stabiilsem, aga ka see vajaks kolme seemet ja usaldusvahemikke. See on järgmine töö.

«Kas inimene on tulemusi hinnanud?»

Peaaegu mitte, ja see on suurim auk. Testis on 47 ülesannet, mis nõuavad inimhinnangut, ja need on siiani hindamata. Automaatika mõõdab oskusi, loomulikkust ta ei näe. Kõige huvitavamad vead leidsin ise mudeliga vesteldes, mitte testiga.

«Kust te andmed võtsite ja kas teil oli luba?»

Põhiallikad on avalikud või kokku lepitud: Riigikogu stenogrammid, Riigi Teataja, ERR, TalTechi avaldatud andmestikud ja Tartu Ülikooli koondkorpus, mille litsentsi küsisin eraldi kirjaga üle ja millele viitan. Ma ei ole ühtegi kogu automaatselt kraapinud, ja iga korpuse kirje kannab allika- ja litsentsivälja. Aga ma pean tegema ühe vahe, mida on kerge maha vaikida: avaldamisest väljas ei ole sama mis treeningust väljas. Määramata litsentsiga kirjed ja masinaga genereeritud materjal on avaldatavast paketest välja jäetud ja eraldi märgistatud, aga osa neist oli treeningus sees. See oli teadlik otsus, mitte kogemata. Ma treenisin ilma kindla litsentsikinnituse ja tõmbasin piiri avaldamise, mitte treeningu juurde, sest levitamine on see koht, kus kahju muutub pöördumatuks. Ma ei väida, et see on õige vastus, ja mul ei ole selle kohta õigusnõu. Kui teil on siin väljakujunenud praktika, siis ma tuln seda kuulama, mitte oma valikut kaitsma.

«Miks Qwen ja mitte mõni muu mudel?»

Kolm põhjust: Apache 2.0 litsents, mis lubab vabalt kasutada ja avaldada; 27 miljardit parameetrit mahub tihendatult ühele 32 GB kaardile; ja tema eesti keele lähtetase oli mõõtes parim nendest, mida katsetasin. Metoodika ise mudelist ei sõltu: sama torustiku saab järgmise baasmudeli peale jooksutada.

«Miks ainult 110 miljonit tokenit? See on väga vähe.»

Täiesti õige, see on kaasaegse eeltreeningu mastaabis umbes kümnetuhandik. Piirang on riistvara: üks kaart annab umbes 870 tokenit sekundis, ehk 110 miljonit võttis 35 tundi. Ma tegin selle teadlikult piloodina, et mõõta, kas suund üldse tasub. Lävi, mille ma endale ette seadsin, oli 5 kuni 10 protsenti perpleksuse paranemist; tuli 31. Lisan kohe ka selle, et algul kirjutasin igale poole 131 miljonit, see oli korpuse suuruse hinnang, mitte see, mis mudelini jõudis. Vahe kadus karpimisel, sest ma arvutasin tükkide pikkust tähemärkides ja eesti keele tähemärk-tokeni suhtega valesti.

«Kas te tegite need 13 annust ka ühe jooksuna, sama tokeni- ja sammuarvuga? Kust te teate, et kasu tuli iteratsioonist?»

Ma ei tea seda. Mul on kaks jooksu: üks suur annus andis 76,5 ja kolmteist ringi andsid 85,3. Aga need kaks ei olnud muus osas identsed, ja mis veelgi tähtsam, iteratiivses harus koostati andmed vahepealsete vigade põhjal. Nii et seal on korraga kaks hüpoteesi: kas kasu tuli mitmes järgus treenimisest, või sellest, et andmed olid iga kord sihitud. Need ei ole sama küsimus ja minu katse ei lahuta neid. Aus lause on: see retsept andis parema tulemuse kui minu ühe annuse lähtekatse.

«Kas mudel ei unustanud muid oskusi ära?»

Mõõtsin seda, sest see oli reaalne risk. Üldteadmiste test langes 68,7 pealt 66,0 peale ja programmeerimine tõusis 71,3 pealt 85,4 peale. Katastroofilist unustamist, mis tähendaks kümneid punkte, ma ei näinud. Kasutasin ka kordust: jätku-eeltreeningul 3,1 protsenti sõnadest, SFT-ringides 15 kuni 18 protsenti näidetest. Aga ma ei saa öelda, et kordus oli see, mis päästis, sest ma ei teinud sama treeningut ilma korduseta. Ilma võrdluspaarita ei ole mul põhjuslikku väidet, on ainult üks jook.

«Kas perpleksus langes ka uudistes, ametikeeles ja kõnekeeles, või ainult sellises tekstis, millega te treenisite?»

Ma mõõtsin ainult ühel žanril, ja see oli seesama toimetatud proosa, kust CPT-korpus tuli. Nii et kõige ausam lugemine on: mudel kohanes sellele tekstitüübile. Kas ta läks paremaks ka uudistes või ametikeeles, ma ei tea. See on lihtne katse ja see on tegemata. Lisan veel ühe puuduse: mu kõrvalepanek käis lõigu tasandil räsi järgi, mitte teose ega autori tasandil. Kuna korpus on ilukirjandus, on täiesti võimalik, et sama autori teine peatükk oli treeningus, ja see lahjendaks tulemust.

«Millise Vabamorfi versiooniga te hindasite ja kuidas te käsitlesite mitmeseid analüüse ja rööpvorme?»

Ma ei fikseerinud versiooni manifesti, ja see on puudus, mille ma parandan ära. Rööpvormidega läks nii, et minu hindaja lugus alguses valeks vorme, mis olid tegelikult õiged, sest ta tundis ainult üht varianti. Kui ma selle parandasin, tõusis skoor ilma et mudel oleks muutunud, ehk osa minu paranemisest oli mõõteriista paranemine. Mitmese analüüsi ja pärisnimede kohta ei ole mul süstemaatilist poliitikat, on üksikud otsused. Ja seal on veel üks põhimõtteline asi: ma lõin ülesanded Vabamorfiga ja hindasin neid sama Vabamorfiga. See mõõdab osaliselt kooskõla ühe tööriistaga, mitte kogu eesti keelt. Teie oskate mulle öelda, kui suur see vahe on.

«Kas Q4 rikkus mudeli tõesti kvantimise pärast, või oli asi milleski muus?»

Ma ei tea kindlalt. Mul on üks vaatlus: pärast jätku-eeltreeningut tõi Q4 tagasi ortograafiavead, mis olid treeninguga parandatud, ja Q6 juures neid ei olnud. Ma ei korranud seda mitme kvantijaga, mitme seemnega ega Q8-ga vahepeal. Nii et alternatiivsed seletused: vale teisendus, mall, või liitmise samm, on lahti. Praktiline soovitus jääb siiski samaks: kui oled teinud CPT, kontrolli kvantimise mõju eraldi üle, sest see on odav kontroll ja mina sain kinnitust, et seal on midagi vaadata.

«Kas te tegite mudelile jäädvustamise testi? Kas sealt tuleb välja tükke koondkorpusest?»

Ei teinud, ja ma ei saa seetõttu öelda, et ei tule. See on minu nimekirjas järgmine töö. Meetod on teada: võtta haruldased treeninglõigud, anda mudelile nende algus ja mõõta, kui pikalt ta jätkab sõna-sõnalt. Ma tean, et mudelid võivad treeningteksti jäädvustada (see on mitmel korral mõõdetud), ja ma ei taha seda oma mudeli kohta ette ära arvata kummaski suunas.

«Kas CC-BY-SA korpusest treenitud mudeli avaldamise õigusliku poole on jurist üle vaadanud?»

Ei ole. Ma ei ole jurist ja ma ei ole õigusnõu küsinud. Korpuse litsentsi ma küsisin kirjaga üle ja mul on see kirjalikult olemas. Aga küsimus, kas treenitud kaalud on juriidiliselt tuletatud teos, on lahtine ja jurisdiktsiooniti erinev. Ma olen valinud konservatiivse tee: märgin allikad, avaldan sama litsentsi all, ja kui õiguste omanik ütleb, et ei sobi, võtan maha. See on hoiak, mitte õiguslik argument. Kui EKI-l on selles seisukoht, tahan seda kuulda, sest see puudutab kõiki, kes eesti keele mudeleid avaldavad.

«Mis on selle töö nõrgim koht?»

Vestlus. Mudel on tugev ülesannetes, aga mitmekäigulist dialoogi ta pole kunagi näinud, ja see paistab välja: ta kaotab konteksti ja vahel kajab küsimuse tagasi. Kõige tõenäolisem põhjus on treeningandmete kuju: kogu treening oli üksikute küsimuste ja vastuste kujul. Ma ei ole seda kontrollkatsega isoleerinud, nii et kaasa võivad aidata ka vestlusmall, maskimine ja pakendamine. Parandamiseks oleks vaja päris eestikeelset dialoogi, mida avalikult peaaegu ei ole. Teie Vikipeedia arutelude korpus on selles mõttes haruldane materjal.

«Kas tehisintellekt ei hakka niikuinii eesti keelt ise oskama, kui mudelid suuremaks lähevad?»

Osaliselt jah, aga mitte iseenesest. Mudel oskab seda, mida on tema andmetes. Kui eesti teksti on avalikult vähe ja see vähene on tõlgitud, siis suurem mudel teeb sama vea suurema enesekindlusega. Just sellepärast on tähtis, et kvaliteetne eesti tekst oleks kättesaadav siis, kui järgmisi mudeleid ehitatakse. See on ka minu töö tegelik eesmärk: mitte see üks mudel, vaid see, et materjal ja meetod oleksid olemas.

«Mis on teie huvi? Kas te müüte midagi?»

Ei müü. Sellel tööil ei ole minu jaoks majanduslikku kaalu, ei otsest ega kaudset. Teen seda, et eesti keel oleks avatud mudelites sama hea kui tasulistes, ja et tehtud töö kanduks edasi. Sellepärast on kõik avalik, sealhulgas ebaõnnestumised.

«Mis kasu on sellest meile?»

Kolm asja. Meetod on korratav ja dokumenteeritud, ka koos sellega, mis ei töötanud, teie peenhäälestusandmete projekt saab need vead vahele jätta. Litsentsipuhas käänamiskorpus on olemas ja kasutatav. Ja puhas eeltreeningu adapter on eraldi avaldatud, nii et saab uurida, mida teeb 110 miljonit tokenit toimetatud proosat ilma ühegi oskusdrillita. Kui midagi sellest teile kasulik on, on see minu jaoks selle töö parim tulemus.

XII osa. Sõnastik

Viimane pilk enne kohtumist.

Keeleteadus

Mõiste	Ühe lausega
Morfoloogia	Õpetus sõnavormidest; eesti keeles 14 käänat ja 2 arvu.
Lemma	Sõna sõnaraamatukuju (raamat), vastandina vormile (raamatusse).
Tüvi	Sõna osa, mille külge lõpud liituvad.
Astmevaheldus	Tüvi ise muutub käänamisel: kurb → kurva → kurbade.
Ühildumine	Omadussõna käib nimisõnaga kokku käändes ja arvus; nelja viimase käände puhul jääb omastavasse.
Reksioon	Verb nõuab kindlat käänat: sarnaneb isaga, mitte isale.
Rööpvormid	Sama tähendus, mitu õiget vormi: suurde märke / suuresse mäesse.
Morfoloogiline analüüs	Vormist teadmiseni: raamatusse → lemma raamat, ainsuse sisseütlev.
Morfoloogiline süntees	Teadmisest vormini: raamat + sisseütlev → raamatusse.
Ringkontroll	Genereeri vorm, analüüsi tagasi, viska ära kui lemma ei klapi.

Masinõpe

Mõiste	Ühe lausega
Token	Tükk, milleks tekst mudeli jaoks jaotatakse; eesti sõna 2,37, inglise 1,11 tokenit (meie mõõdetud).
Parameeter / kaal	Üks mudeli sisemistest arvudest; meie mudelis 27,78 miljardit neist.
Kontekstiaken	Kui palju teksti mudel korraga näeb.
Baasmudel	Suur eeltreenitud mudel, mille peale ehitad.
Eeltreening	Toorteksti õpetamine nullist; ainult suurte laborite töö.
CPT (jätku-eeltreening)	Toortekst valmis mudelisse: annab KEELE.
SFT (juhendatud peenhäälestus)	Küsimuse-vastuse paarid: annavad OSKUSED.
DPO (eelistusõpe)	Kaks vastust, üks parem: optimeerib parema eelistamist halvemale. Kasutab külmutatud viitemudelit.
RLHF	Eelistusõpe eraldi ÕPITAVA hindajamudeliga. DPO ei ole seda asendanud, ainult lisandunud.
LoRA	Väike juurdeõpetatav kiht külmutatud mudeli peal.
QLoRA	LoRA, kus baasmudelit hoitakse mälus 4-bitisena.
Adapter	Selle juurdeõpetatud kihi fail; eraldi baasmudelist.
Rank	Adapteri mahutavus (8-128); suurem ei ole automaatselt parem.

Mõiste	Ühe lausega
Alpha	Adapteri mõjujõud; sageli kaks korda rank, aga see on tava, mitte reegel.
Liitmine (merge)	Adapteri arvutamine baaskaaludesse: tulemuseks üks fail.
Sulatamine (merging)	Kahe eri mudeli kaalude kokkuliitmine ilma treeninguta (SLERP, TIES, DARE).
Õpisamm (LR)	Kui suure sammu mudel iga paranduse juures teeb.
Kadu (loss)	Treeningaegne eksimus. Absoluutväärtus sõltub ülesandest ega tõesta üksi midagi.
Valideerimiskadu	Kadu kõrvale pandud andmetel. Ainus, mis näitab päheõppimist: tõuseb, kui treeningkadu veel langeb.
Ülesobitumine	Mudel õpib treeningnäited pähe, üldistus halveneb. Diagnoos on kahe kaokõvera lahknemine, mitte ükski üksik arv.
Kontrollpunkt	Mudeli salvestamine treeningu keskel, et saaks lõpuks võtta parima, mitte viimase.
Varajane peatamine	Treeningu lõpetamine, kui valideerimiskadu enam ei parane.
Arenduskomplekt	Ülesanded, mille järgi sa OTSUSEID teed. Nii tihti vaadata kui tahad.
Testikomplekt	Ülesanded, mida vaadatakse ÜKS kord, pärast kõiki otsuseid. Iga järgmine kord nõrgendab teda.
Ablatsioon	Kontrollkatse, kus üks koostisosa võetakse ära, et näha, mida ta tegi.
Seeme	Algväärtus, mis peaks juhusliku protsessi korratavaks tegema. Üks seeme = üks vaatluspunkt.
Jooksumanifest	Ühe treeningjooksu saateleht: kõik, mida keegi teine vajab selle kordamiseks.
Jäädvustamine	Mudel annab treeningteksti sõna-sõnalt tagasi. Korruga privaatsus- ja autoriõiguse risk.
Epohh	Üks täisläbimine andmestikust.
Gradiendi kogumine	Mitme näite paranduste liitmine enne rakendamist.
Pakkimine (packing)	Lühikeste tekstide kokkukleepimine täisakendeks. Ka SFT-s tavaline, kui eraldajad ja maskid on õiged.
Soojendus (warmup)	Väikese õpisammuga algus, et optimeerija arvepidamine jõuaks kalibreeruda.
Optimeerija (AdamW)	Otsustab, kuidas parandused kaaludesse kantakse.
Perpleksus (perplexity)	Mudeli üllatuse mõõt ÜHEL korpusel. Sõltub tükeldajast; võrreldav ainult sama tükeldaja ja sama tekstiga.
Replay (kordus)	Vana materjali segamine treeningusse unustamise vastu.
Katastroofiline unustamine	Uue õppimine kustutab vana oskuse.
Kvantimine	Kaalude tihendamine (Q4, Q6, Q8) mälu ja kiiruse nimel.
GGUF	Failivorming kohalikuks jooksutamiseks (llama.cpp, Ollama).
Leke (contamination)	Testi ülesanded on treeningandmetes; muudab numbrid valeks.
Vestlusmall	Vorming, mis märgib, kus on kasutaja jutt ja kus vastus.

Mõiste	Ühe lausega
Temperatuur	Kui julgelt vastuseid valitakse; 0 tähendab serverites kokkuleppeliselt ahnet valikut, mitte matemaatilist nulli.
MoE	Mudel, kus iga tokeni juures töötab ainult osa parameetritest.
Pass@1	Programmeerimistesti mõõt: mitu protsenti õnnestub esimese katsega.
F1 / EM	Lugemistesti mõõdud: osaline kattuvus / täpne vaste.

Ja lõpuks. Kui sa unustad kogu selle materjali ära ja mäletad ainult ühte asja, siis olgu see see: sa oled selles ruumis inimene, kes on üksi, oma arvutiga, ühe väikese keele nimel selle tee algusest lõpuni läbi käinud ja iga sammu üles kirjutanud, ka need, mis ebaõnnestusid. Nemad tunnevad põhjalikult keelt ja meetodeid. Sina tood ruumi ühe tervikuna dokumenteeritud praktilise juhtumi. Just seepärast sind kutsuti.